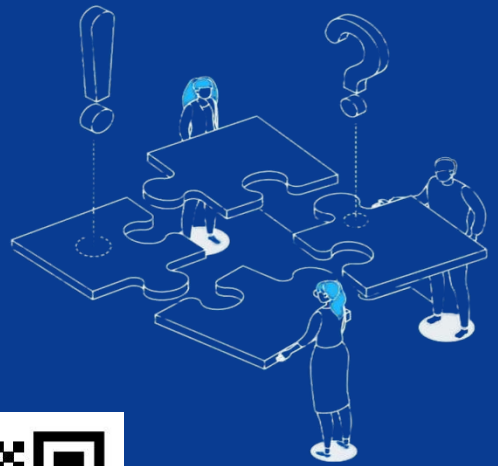
自然语言处理（NLP）中的伦理挑战：面向学生与研究人员的实践策略



Xi Ai, Vamshi Krishna Bonagiri, Monojit Choudhury, Abdoul Jalil Djiberou Mahamadou, Esther Gan, Zhijing Jin, Min-Yen Kan, Seunghun J. Lee, Yisong Miao, Margot Mieskes, Aurélie Névéol, Yajing Yang

Scan here for English version

https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

CC BY



Barid Xi Ai

新加坡国立大学,
新加坡



Vamshi Krishna Bonagiri

穆罕默德·本·扎耶德人工智能大学，*阿联酋*



Monojit Choudhury

穆罕默德·本·扎耶德人工智能大学，*阿联酋*



Esther Gan

新加坡国立大学,
新加坡



Abdoul Jalil Djiberou Mahamadou

穆罕默德·本·扎耶德人工智能大学，*阿联酋*



Zhijing Jin

多伦多大学，*加拿大*及马克斯·普朗克研究所，*德国*



Min-Yen Kan

新加坡国立大学,
新加坡



Seunghun Lee

国际基督教大学，*日本*及文达大学，*南非*



Yisong Miao

新加坡国立大学,
新加坡



Margot Mieskes

达姆施塔特应用技术大学，*德国*



Aurélie Névéol

LISN-CNRS / 巴黎萨克雷大学，*法国*



Yajing Yang

新加坡国立大学,
新加坡

课程介绍与
课前问卷调查

Min-Yen Kan
新加坡国立大学

扫码获取教程和学习资料

实践活动幻灯片

https://soc-n.us/261109-ethics-tutorial-activity

主讲演示幻灯片

https://soc-n.us/261109-ethics-tutorial-slides

（当前浏览幻灯片）

https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

议程

时间	活动	主讲人
9:00–9:10	介绍与开场	Min
9:10–9:40	伦理的哲学基础	Yajing, Esther, Yisong
9:40–10:05	环境与社会影响	Margot, Aurélie
10:05–10:30	小组讨论	*全体参与者*
10:30–11:00	 □ *茶歇* □ 	
11:00–11:40	小组展示	*全体参与者*
11:40–11:50	ACL 会议论文中的伦理考量章节	Yisong
11:50–12:20	语言表达与多语言偏见	Vamshi, Barid, Seunghun
12:20–12:30	总结与闭幕	

https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

伦理的哲学基础

Esther Gan, Yajing Yang, Yisong Miao
新加坡国立大学

说明

本教程这一部分的原始幻灯片可在此处获取（源自 Karën Fort 和 Fanny Ducel，已获授权使用）：

https://soc-n.us/261109-ethics-slides-source

不过，为方便大家查阅，我们也将其直接整合到了本演示文稿中；部分内嵌页面为图片格式，不含可选中的底层文本。

为什么应该关注伦理问题？

- **因**为我们是生活在这个世界上的公民
- **因**为符合伦理的产品销量更好 [Spiekermann, 2015]
- **因**为作为 NLP **科研工作者，如果你不去关注，其他缺乏**专业知识的人就**会代**劳

一个长期困扰我们的问题

道德问题的根源

美德伦理

义务伦理

功利主义

伦理与NLP

总结

一个长期困扰我们的问题（或许是最古老的问题？）





From Lysippe — Eric Gaba (User:Sting),

July 2005., CC BY-SA 2.5

伦理学源于哪个学科领域……



哪个学科或领域最常思考伦理问题？



处理（NLP 领域）伦理问题的国际机构

- ACL 伦理委员会（自 2021 年起）
- 伦理审稿主席（自 2021 年起，各会议及 ACL ARR）
- 标准（由 ACL 采纳）：https://www.acm.org/code-of-ethics

科学必然是向善的吗？

是否存在一些技术上可行，但我们一致认为不应当去做的事？



(c) https://www.starwars.com/databank/clone-troopers

科学研究的方法必然是向善的吗？

是否存在一些技术上可行，但我们一致认为不应当去做的事？

《纽伦堡法典》（The Nuremberg Code）

雏形始于更早时期，最终定稿于 1947 年“医生审判”期间

共包含 10 项基本原则，核心包括：

- 尊重受试者：
  - 知情同意
  - 随时退出实验的自由
- 行善原则：
  - 风险与收益的平衡
- 公正原则：
  - 为社会带来积极成果



731事件

日本帝国军队, 平房(哈尔滨, 中国), 1930s–1945



《贝尔蒙报告》（The Belmont Report）[Bel, 1979]

源于对“**塔斯基吉梅毒**实验”（1932–1972 **年**）**的**伦理反思

该报告**确立了** 3 项基本原则：

- **尊重受**试者：
  - **知情同意**
- **行善原**则：
  - 风险与收益的平衡
- **公正原**则：
  - **公平遴**选受试者



一个长期困扰我们的问题

道德问题的根源

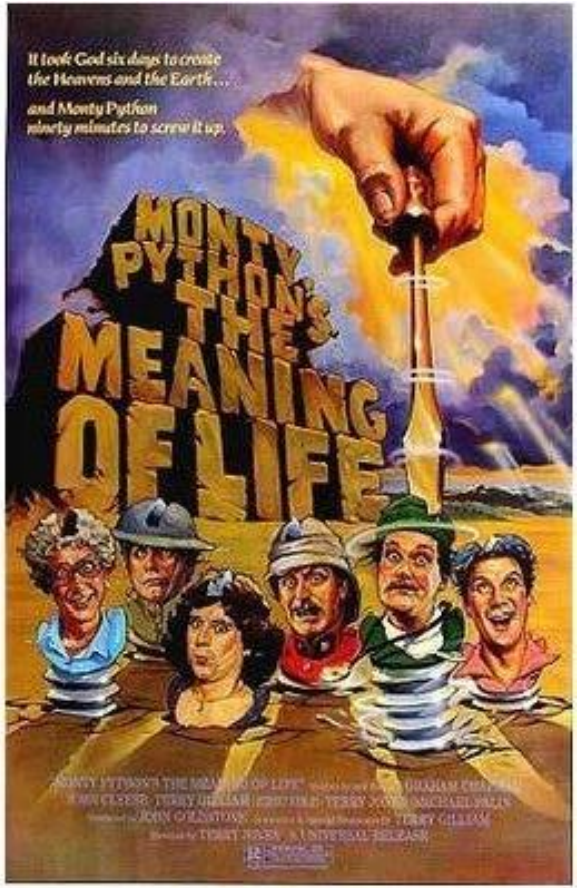
美德伦理

义务伦理

功利主义

伦理与NLP

总结



(c) 1983 Universal City Studios. All rights reserved.

什么是美好的生活？



人类应该如何实现美好的生活

一个长期困扰我们的问题

道德问题的根源

美德伦理

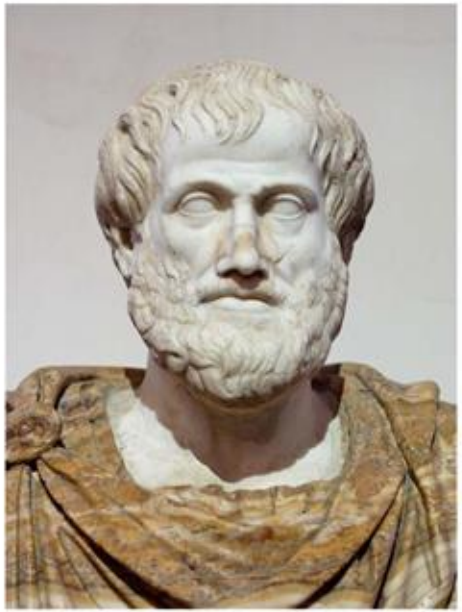
义务伦理

功利主义

伦理与NLP

总结

亚里士多德（Aristotle，公元前 384–322 年）



After Lysippos - Jastrow (2006)

代表性伦理著作

《**尼各**马可伦理学》（Nicomachean Ethics）

伦理关乎行动（而非空谈理论）

做最好的事，作最佳的选择：**有德之人即是践行美德的大**师（**完善**论，perfectionism）

如何实现这一点：

- **在**实践中操练美德
- **与有德之人**为伴

核心美德 = 审慎（PRUDENCE）（**无**过无不及）

一个长期困扰我们的问题

道德问题的根源

美德伦理

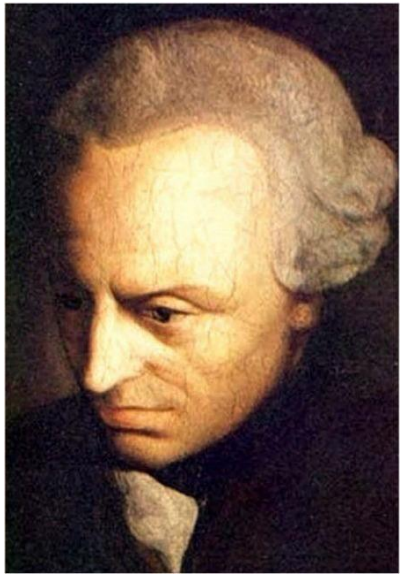
义务伦理

功利主义

伦理与NLP

总结

康德 · 义务论（Immanuel Kant， 1724–1804）



无论结果如何，有哪些规则是绝对不能打破的？

NLP：**必**须强制执行不可妥协**的安全**护栏和隐私权保护措施，**无**论这对模型而言有多么“**有用**”。

道德工作：

对纯粹理性的批判
对实践理性的批判

实践行动以理性为基础

目标：出于职责去做本质上正确的事情，而不是因为感觉、冲动或外部奖励。

如何实现：

- **用理性来控制自己的欲望，而不是被短期的欲望所控制**
- **尊重所有人固有的尊**严 -> 绝不将他人仅仅用作工具或踏脚石核心视角：思考**什么**样的行为本身是**“正当**（right）**”的**

黄金法则：无论最终结果是否顺心如意，都应遵循道德义务与普遍准则。

一个长期困扰我们的问题

道德问题的根源

美德伦理

义务伦理

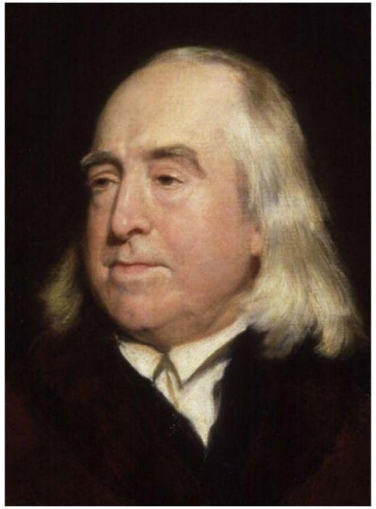
功利主义

伦理与NLP

总结

边沁与密尔 · 功利主义

杰里米·边沁（Jeremy Bentham， 1748–1832）



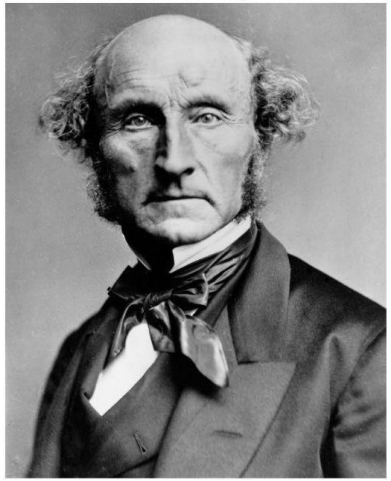
By Henry William Pickersgill

伦理学著作：
《道德与立法原理》

什么样的行动能为最大多数人创造最大的福祉？

NLP：该大语言模型（LLM）是否实现了平均准确率与效用的最大化——即便这意味着少数群体会面临更高的错误率？

约翰·斯图尔特·密尔（John Stuart Mill， 1806-1873）



London Stereoscopic Company - Hulton Archive

伦理学著作：
《关于边沁的论文》

边沁的功利主义

目标：关注结果，而不是意图

如何实现：

- 权衡利弊（好处与坏处权衡）
- **平等**对待每个人：每个人都应被考虑

黄金法则：为最大多数人创造最大利益

电车难题

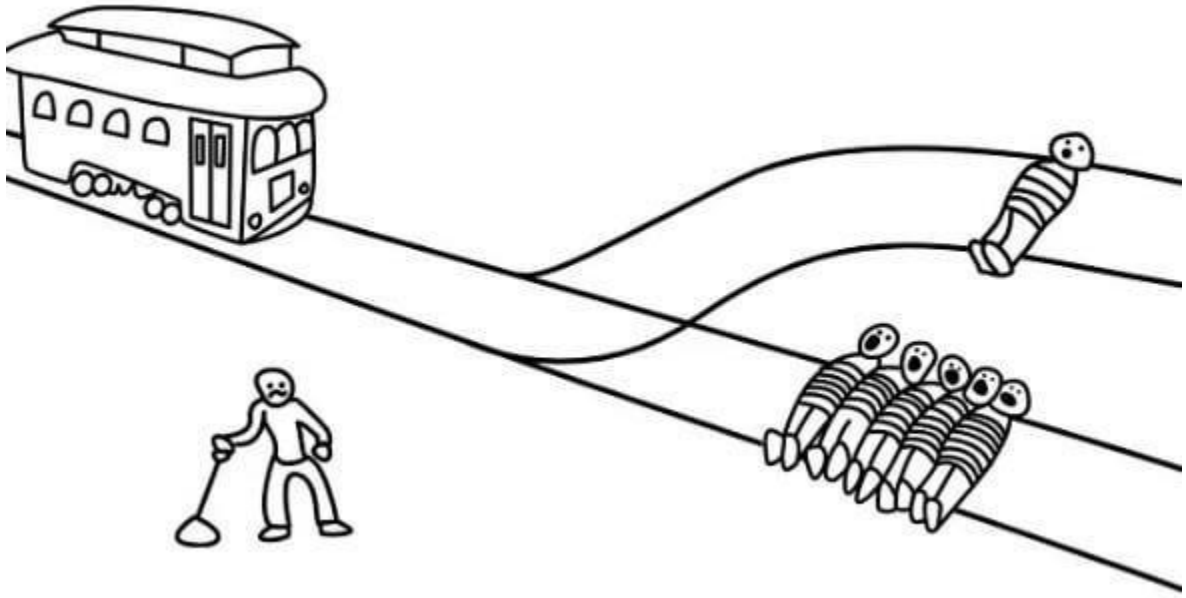


Image source: https://www.reddit.com/r/trolleyproblem/comments/1kkk34v/would_you_rather_kill_5_people_or_1_person/

电车难题

功利主义：拯救 5 条生命 > 失去 1 条生命

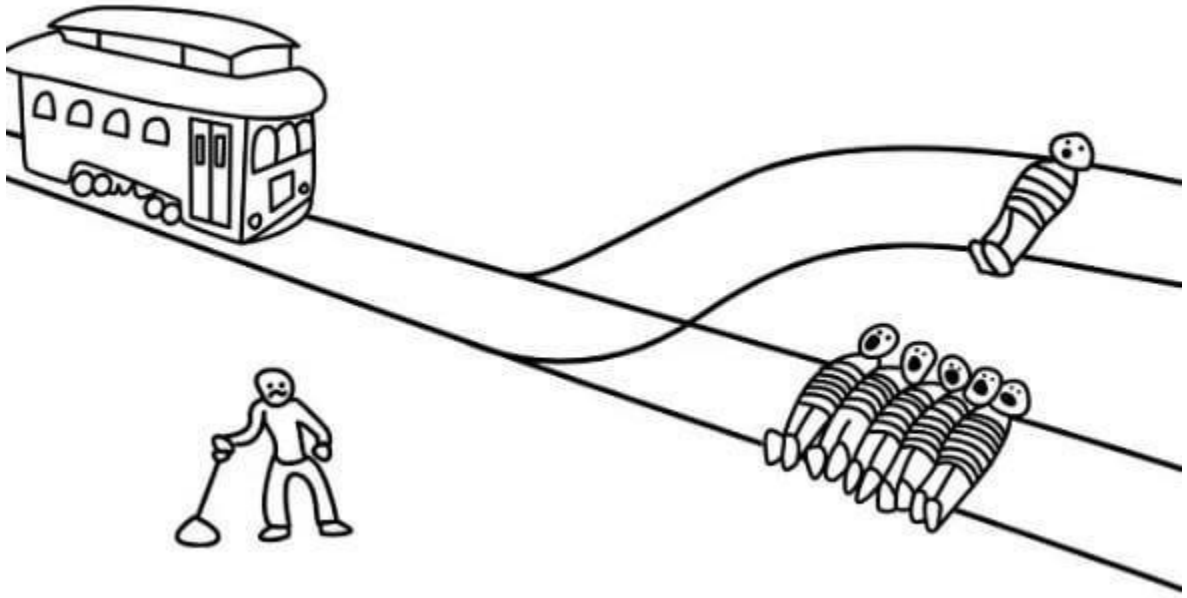


Image source: https://www.reddit.com/r/trolleyproblem/comments/1kkk34v/would_you_rather_kill_5_people_or_1_person/

人行天桥困境

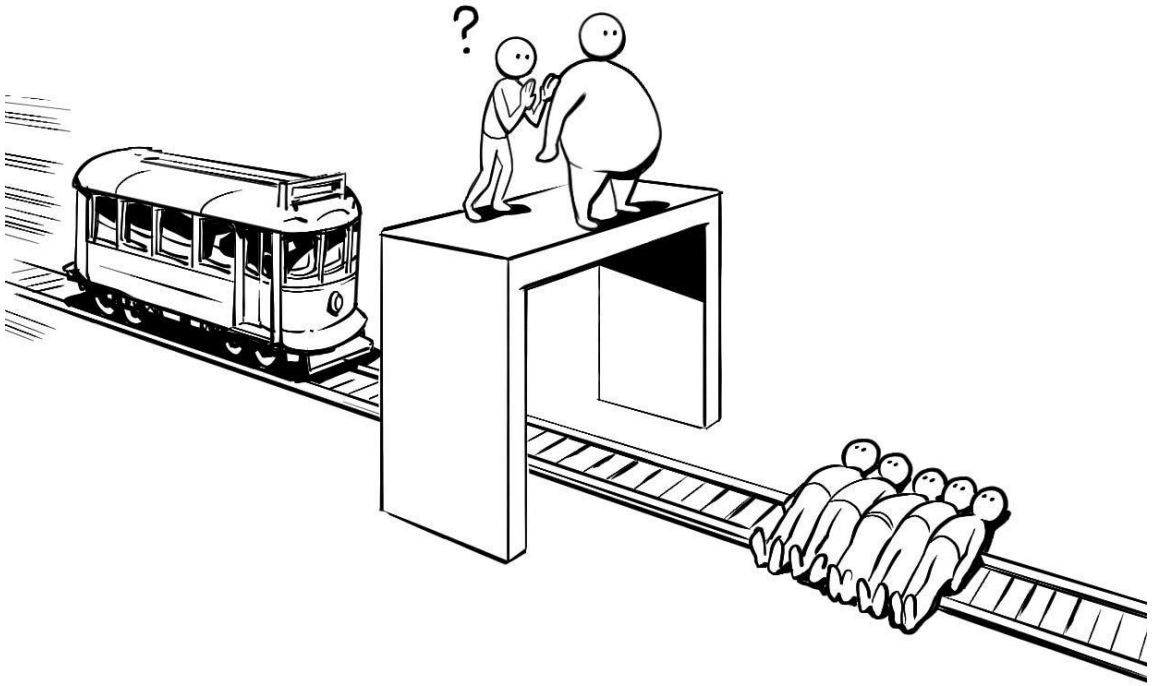


Image source: https://medium.com/@cengizhanbozkurt/a-little-internal-feud-footbridge-dilemma-584c468bae53

人行天桥困境

义务论：利用他人来拯救其**他人，在道德上是**错误的。

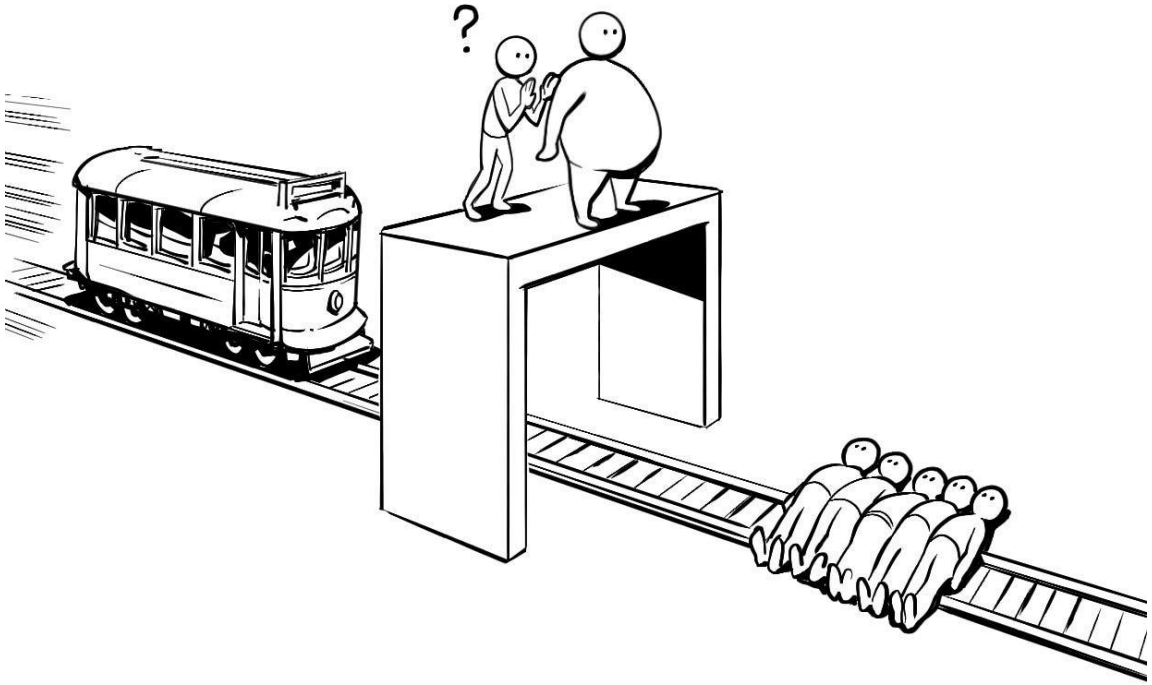


Image source: https://medium.com/@cengizhanbozkurt/a-little-internal-feud-footbridge-dilemma-584c468bae53

一个长期困扰我们的问题

道德问题的根源

美德伦理

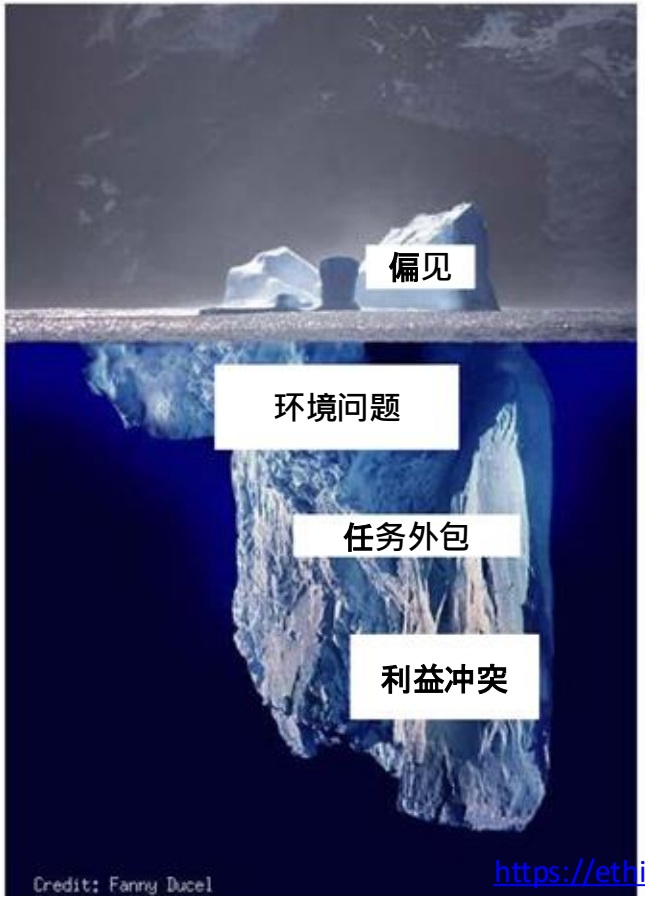
义务伦理

功利主义

伦理与NLP

总结

NLP 中的伦理问题远不止偏见



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

一个长期困扰我们的问题

道德问题的根源

美德伦理

义务伦理

功利主义

道德问题与NLP

总结

假如你是应用哲学家

- 当您调整提示、抓取数据集或评估模型时：
  - 请选择:
    - 这个制度是否平等对待所有语言和方言？
    - **它是否会在流**畅的文本引导下强化有害的偏见和信息？
    - 谁从这个工具中受益，谁承担隐性成本？

处理伦理问题的国际机构（NLP）

- ACL 伦理委员会（自 2021 年起）
- 伦理审查主席（自 2021 年起，涵盖各届会议及 ACL 滚动审稿流程）
- 基于（并由 ACL 采纳）：https://www.acm.org/code-of-ethics

(1979).
The belmont report : Ethical principles and guidelines for the protection of human subjects of research.

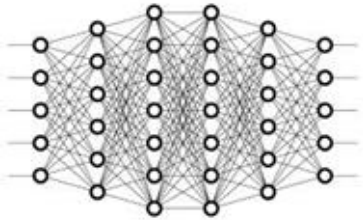
Spiekermann, S. (2015).
Ethical IT Innovation: A Value-Based System Design Approach.
CRC Press.

说明

本教程接下来这一部分的幻灯片改编自 Yulia Tsvetkov 的课程资料，已获授权使用。

小鸡困境





公鸡

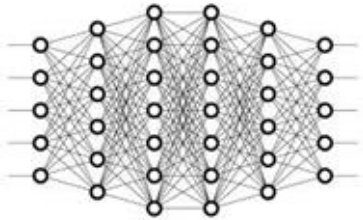


母鸡



小鸡困境





公鸡



母鸡

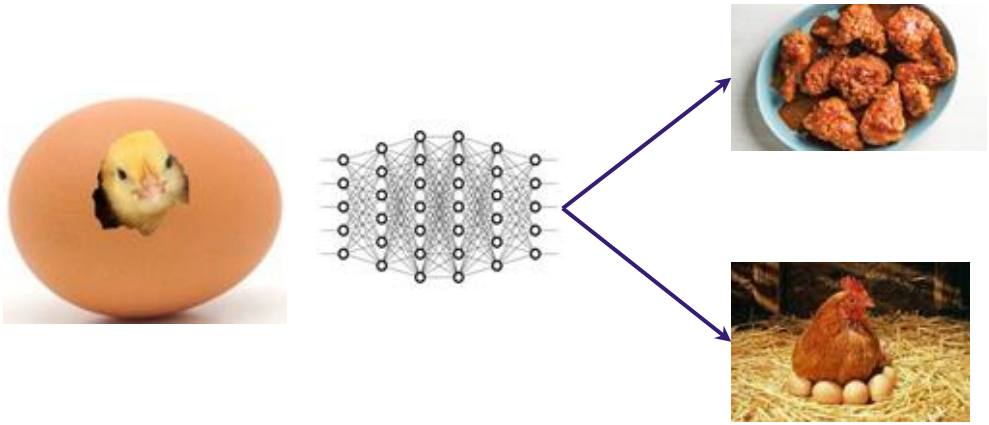


符合伦理吗？

https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

44

小鸡困境

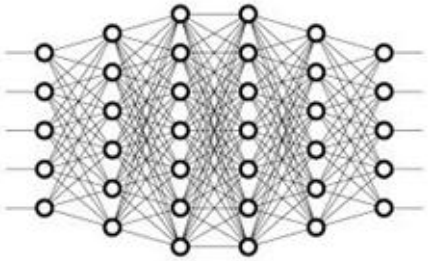


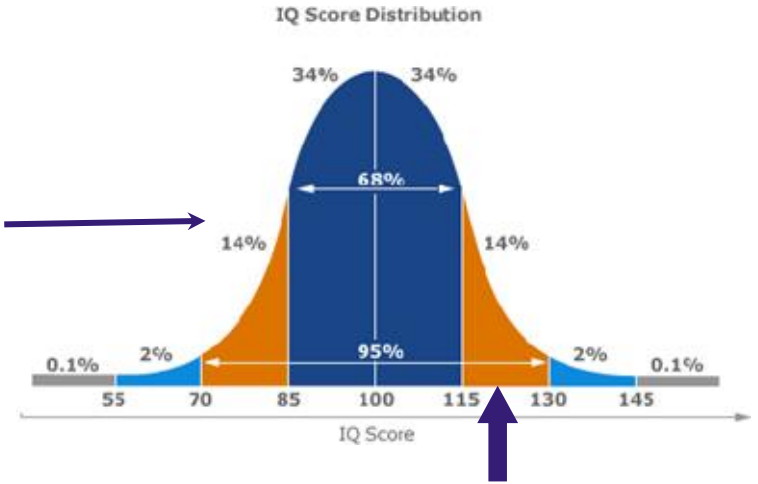
- 伦理是人与社会的内在指引、**道德原**则与价值观
- **其中存在**诸多灰色地带，**我**们往往没有现成的标准答案
- 伦理观念会随着人们的价值观与信仰而不断演变
- **合法 ≠ 合乎**伦理

智商（IQ）困境









➔ **I**ntelligence **Q**uotient（智商）：**衡量个人相**对智力水平的数值

智商（IQ）困境

假设我们尝试训练一个分类器，通过照片和文本来预测智商（IQ）。不妨探讨一下：开发这类技术是否合乎伦理？其中又潜藏着哪些风险？

- 谁会从这样的分类器中获益？

智商（IQ）困境

假设我们尝试训练一个分类器，通过照片和文本来预测智商（IQ）。不妨探讨一下：开发这类技术是否合乎伦理？其中又潜藏着哪些风险？

- 谁会从这样的分类器中获益？
- 如果该分类器达到 100% 准确：
  - 谁会受到这类分类器的伤害？
  - 这类分类器可能会被如何滥用？

智商（IQ）困境

假设我们尝试训练一个分类器，通过照片和文本来预测智商（IQ）。不妨探讨一下：开发这类技术是否合乎伦理？其中又潜藏着哪些风险？

- 谁会从这样的分类器中获益？
- 即便分类器完美无误，谁仍会受到伤害？它又可能被如何滥用？
- 当前方案中存在哪些隐患与风险？
  - 示例：测试结果显示总体准确率为 90%
    - 对白人女性群体的预测准确率为 95%
    - 而对 25 岁以下金发人群的预测准确率仅为 60%

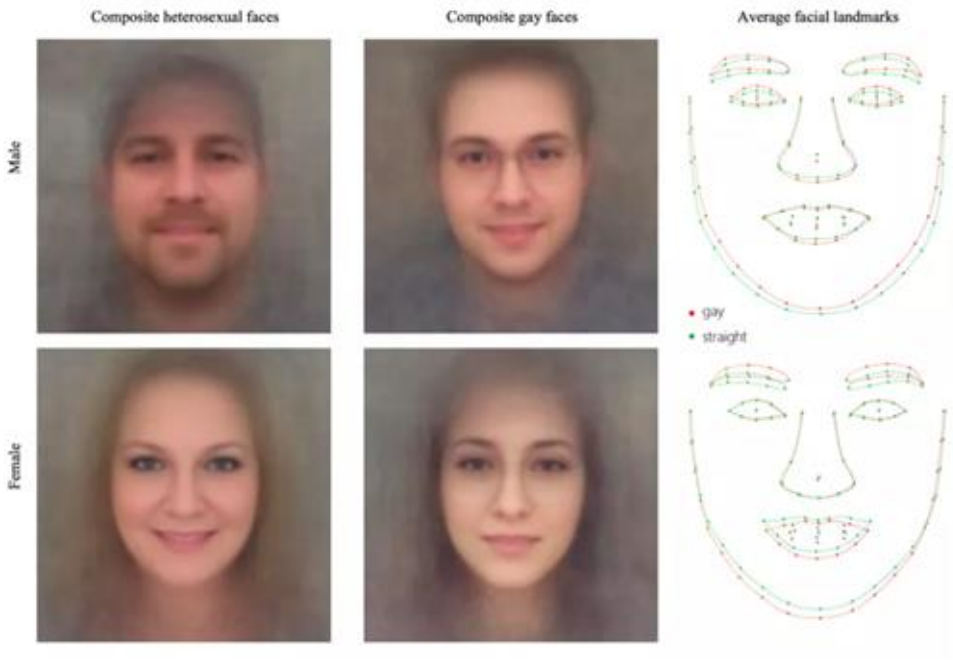
智商（IQ）困境

假设我们尝试训练一个分类器，通过照片和文本来预测智商（IQ）。不妨探讨一下：开发这类技术是否合乎伦理？其中又潜藏着哪些风险？

- 谁会从这样的分类器中获益？
- 即便分类器完美无误，谁仍会受到伤害？它又可能被如何滥用？
- 当前方案中存在哪些隐患与风险？

我们需要意识到自身研究在现实世界中的影响，并理解研究设想与实际后果之间的关系

“AI 同性恋雷达”（AI Gaydar），2017



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

“AI 同性恋雷达”（AI Gaydar）

- 研究问题
  - 根据面部特征识别性取向
- 数据收集
  - 从美国某热门约会网站下载的照片
  - 涵盖 14,776 人的 35,326 张照片（均为白人，同性恋与异性恋、男女比例均衡）
- 研究方法
  - 利用深度学习模型提取面部特征与仪容特征，再通过逻辑回归分类器进行预测
- 准确率
  - 男性为 81%，女性为 74%

“AI 同性恋雷达”（AI Gaydar）

- 研究问题
  - 根据面部特征识别性取向
- 数据收集
  - 从美国某热门约会网站下载的照片
  - 涵盖 14,776 人的 35,326 张照片（均为白人、[illegible]与异性恋、男女比例均衡）
- 研究方法
  - 利用深度学习模型提取面部特征与仪容特征，再通过逻辑回归分类器进行预测
- 准确率
  - 男性为 81%，女性为 74%
- 研究动机：揭示男女同性恋群体在隐私与安全方面面临的潜在威胁

问题出在哪里？

议程

时间	活动	主讲人
9:00–9:10	介绍与开场	Min
9:10–9:40	伦理的哲学基础	Yajing, Esther, Yisong
9:40–10:05	环境与社会影响	Margot, Aurélie
10:05–10:30	小组讨论	*全体参与者*
10:30–11:00	☕ *茶歇* ☕	
11:00–11:40	小组展示	*全体参与者*
11:40–11:50	ACL 会议论文中的伦理考量章节	Yisong
11:50–12:20	语言表达与多语言偏见	Vamshi, Barid, Seunghun
12:20–12:30	总结与闭幕	

自然语言处理中的环境与社会影响

Margot Mieskes

达姆施塔特应用技术大学

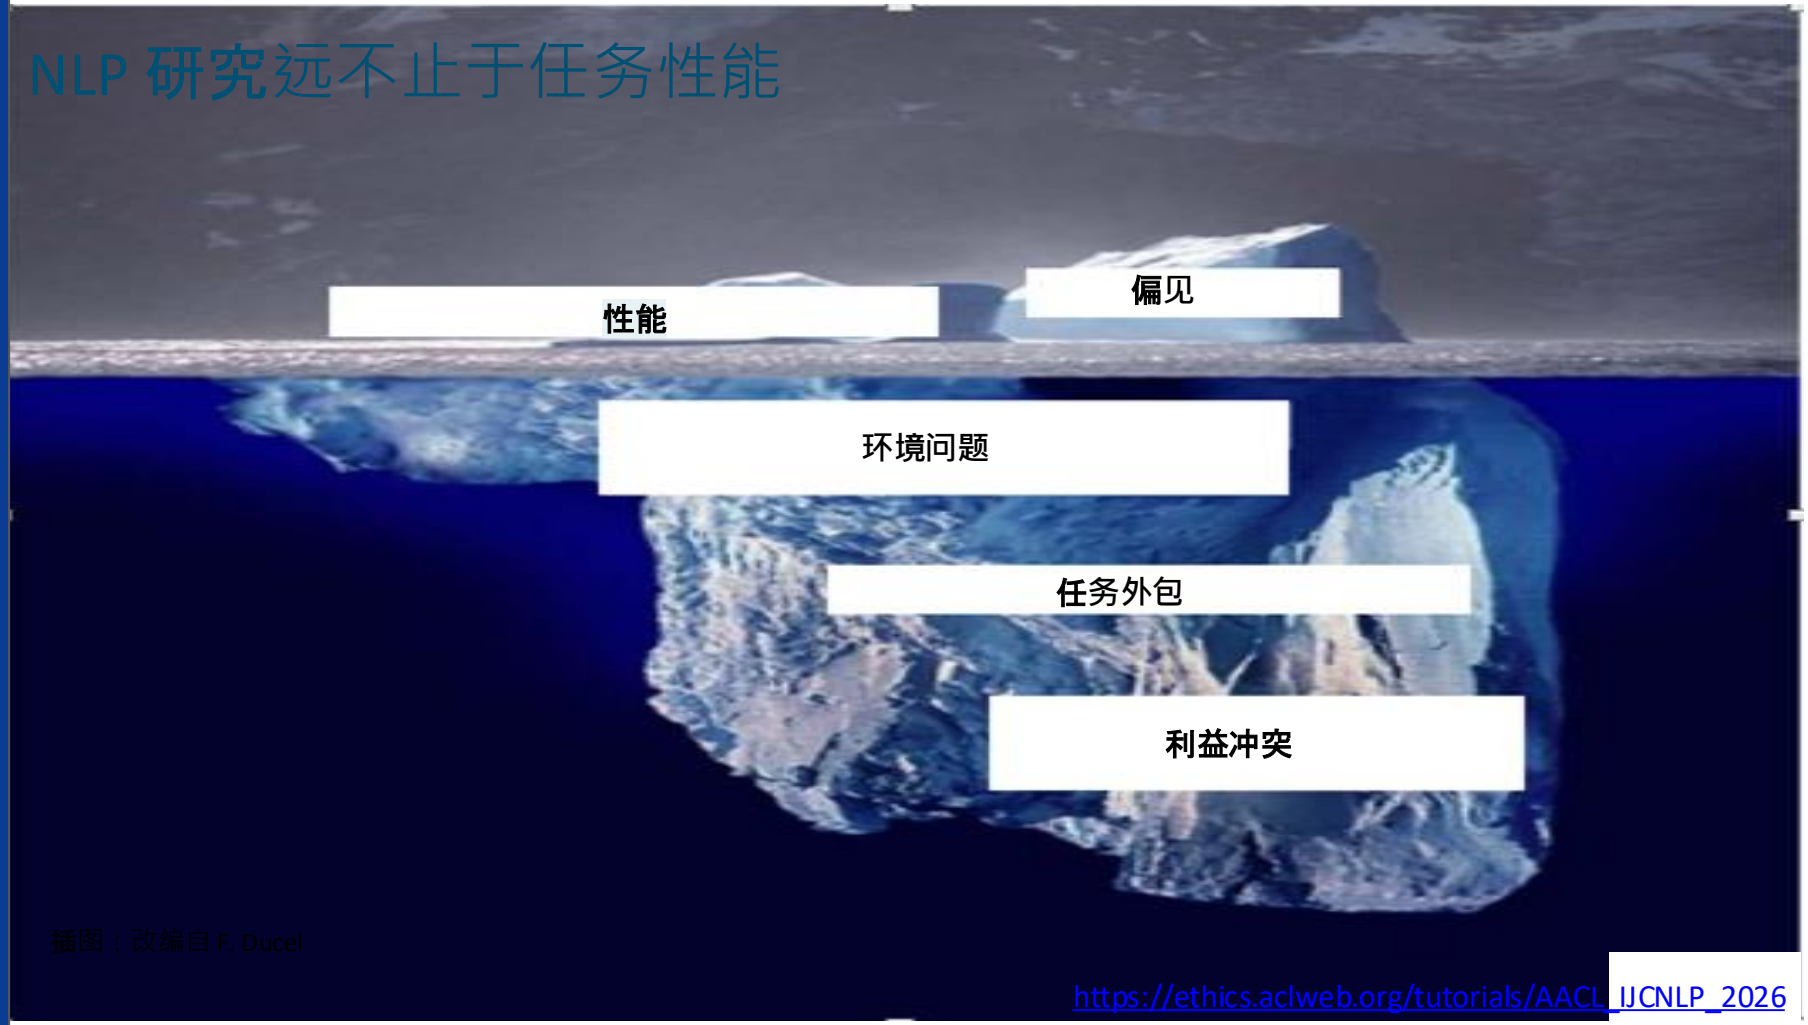
Aurélie Névéol

LISN-CNRS / 巴黎萨克雷大学

小结

评估应涵盖
质量 + **影响**

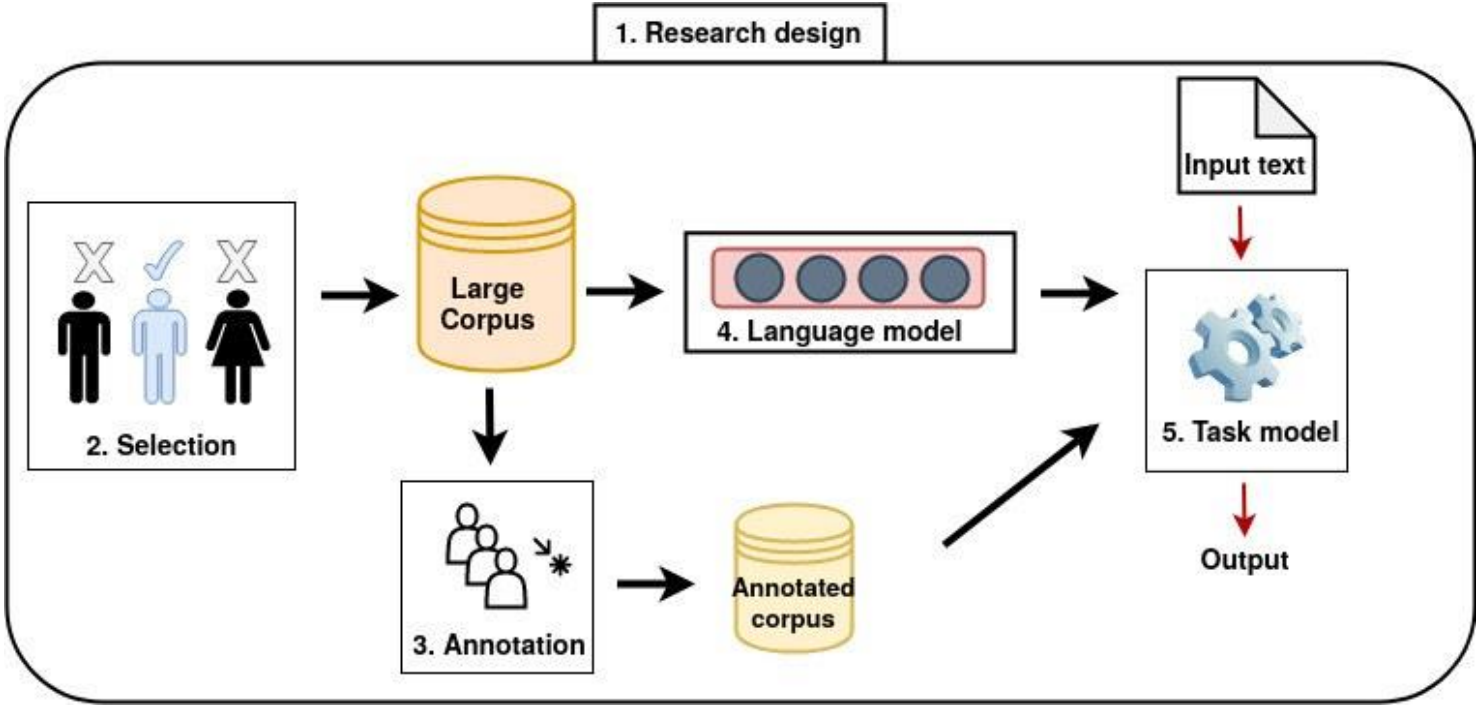
NLP 研究远不止于任务性能



插图：改编自 F. Ducel

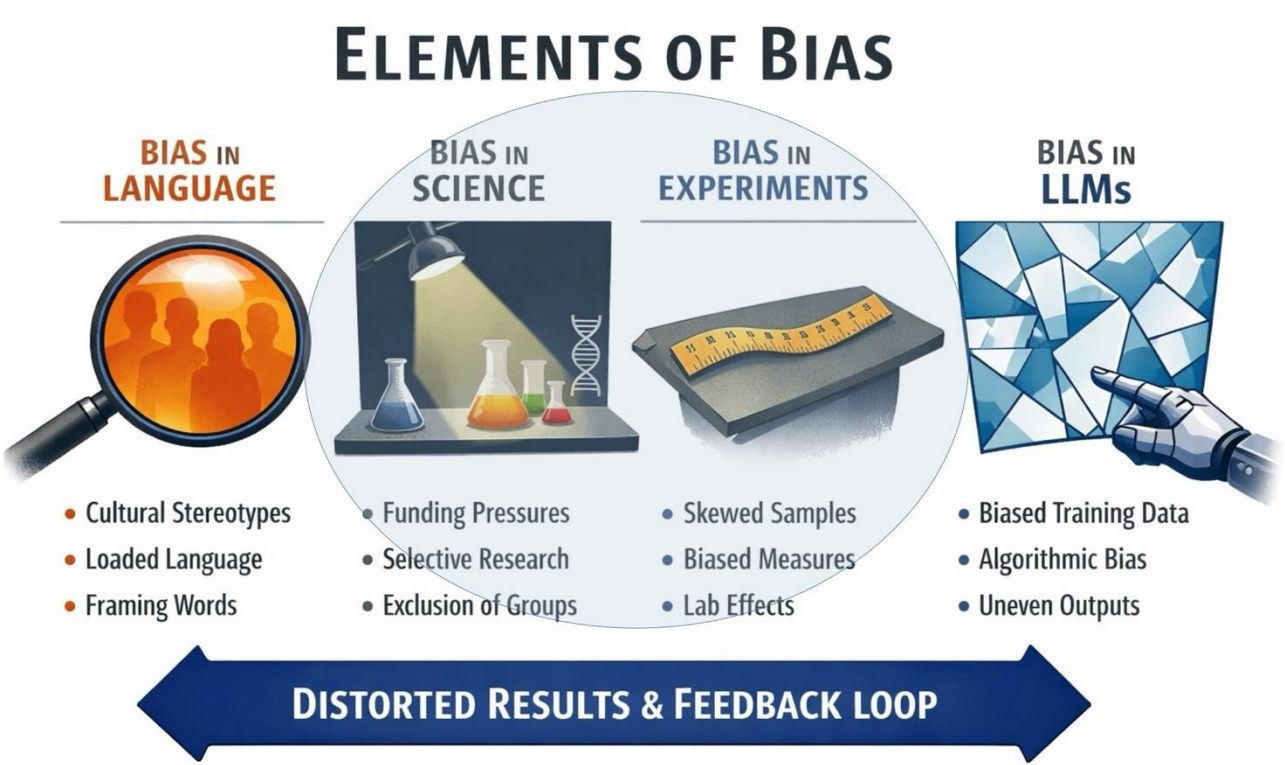
https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

自然语言处理中偏见的五大来源



Hovy D, Prabhumoye S. (2021). 自然语言处理中偏见的五大来源. *Language and Linguistics Compass*, e12432.
https://doi.org/10.1111/lnc3.12432

研究中的偏见



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

示例

- **由于数据稀疏**，针对代表性严重不足群体的研究往往需要更具创造性的方法。

→ 例如：**一个研究空白是**对自闭症谱系女性群体的研究。

- **据美国疾控中心**（CDC）统计，确诊人数持续增加，目前每 36 **名儿童中就有** 1 **名确**诊

这会带来什么后果？

- **你正在分析**谁的数据？
- **你能从中得出什么**结论？
- **哪些**结论可以推广，**哪些不能**？
- **你是否坦**诚、**透明地**说明了研究的局限性？

语言中的偏见——免责声明

请注意：以下示例仅供说明之用，不代表作者及/**或其他主**讲人**的立**场。

语言中的偏见



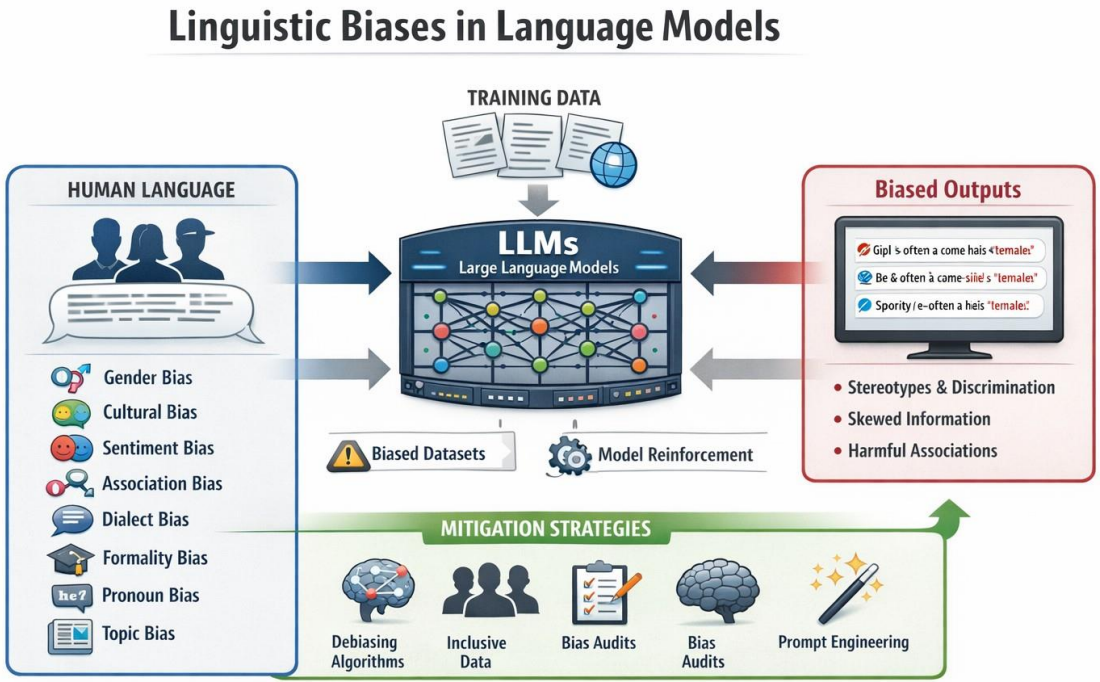
https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

正向偏见与负向偏见



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

存在哪些问题？



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

存在哪些问题？



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

存在哪些问题？



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

存在哪些问题？


ENGLISH DATA
TRANSLATE
FRANÇAIS
ITALIANO
ESPAÑOL
DEUTSCH

偏见从何而来？



偏见从何而来？



这对你的数据意味着什么？

- 你的数据具有怎样的文化背景？
- 你的数据具有怎样的社会背景？
- 你的数据具有怎样的历史背景？

这对你的应用意味着什么？

- **你的**应用具有怎样的文化背景？
- **你的**应用具有怎样的社会背景？
- **你的**应用具有怎样的历史背景？

法国标准化协会（AFNOR）“节俭型 AI（Frugal AI）”规范

共 31 项建议，**其中包括**：

- AI **解决方案**应尽可能高效
- **需**证明采用 AI **系**统相较于其他方案具有明**确收益**
- 应用与需求应保持在地球生态边界之内



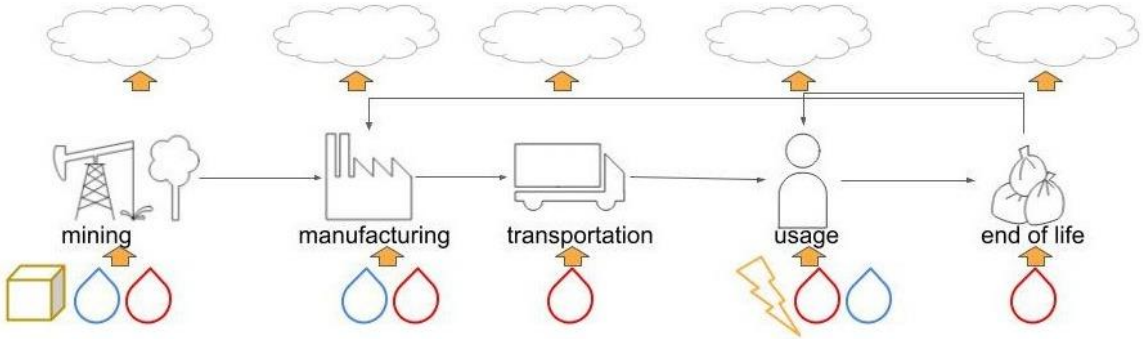
来源

https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

衡量语言模型的环境影响

需要考量的因素：

- **模型的生命周期**：训练、微调、蒸馏、**推理等**
- **硬件**设备
- **硬件的生命周期**



图表改编自 J Combaz 与 A-L Ligozat

基于 85 篇文献综述筛选出的 6 款 CO_2 影响测量工具

- **在线工具**
  1. Green Algorithms
  2. ML CO2 Impact
- **Python 工具包**
  2’. Code Carbon
  3. Energy Usage
  4. Experiment Impact Tracker
  5. Carbon Tracker
  6. Cumulator

+ MLCA github.com/blubrom/MLCA

+ Ecologits ecologits.ai

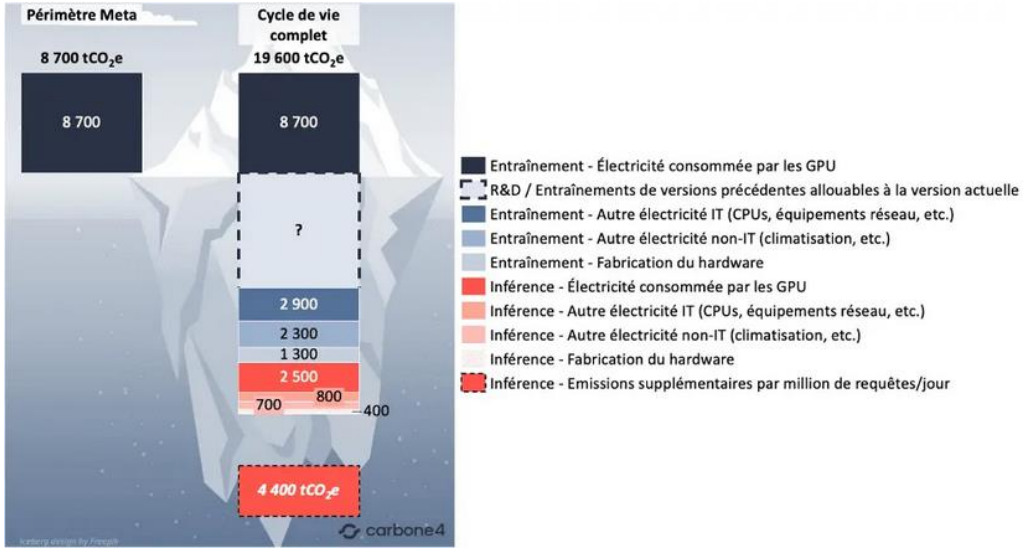
Bannour N, Ghannay S, Névéol A, Ligozat AL. 评估 NLP 方法的碳足迹：现有工具综述与分析. ACL Workshop SustainNLP 2021:11-21
Morand C, Névéol A, Ligozat AL. MLCA：机器学习生命周期评估工具. *ICT4S* 2024

测量工具的特性对比

特性	在线工具	工具包
直接测量	✗	✓ ~
估算	✓	✗
异步计算	✓	✗
同硬件对比	~	✓
易于安装	✓	~

大语言模型（LLM）的环境影响是什么？

- **相关数据很**难获取！
- 训练仅占总环境影响的一小**部分**
  - 约占总影响的 4%



https://www.carbone4.com/ia-generative-du-changement-climatique

大语言模型（LLM）的环境影响是什么？

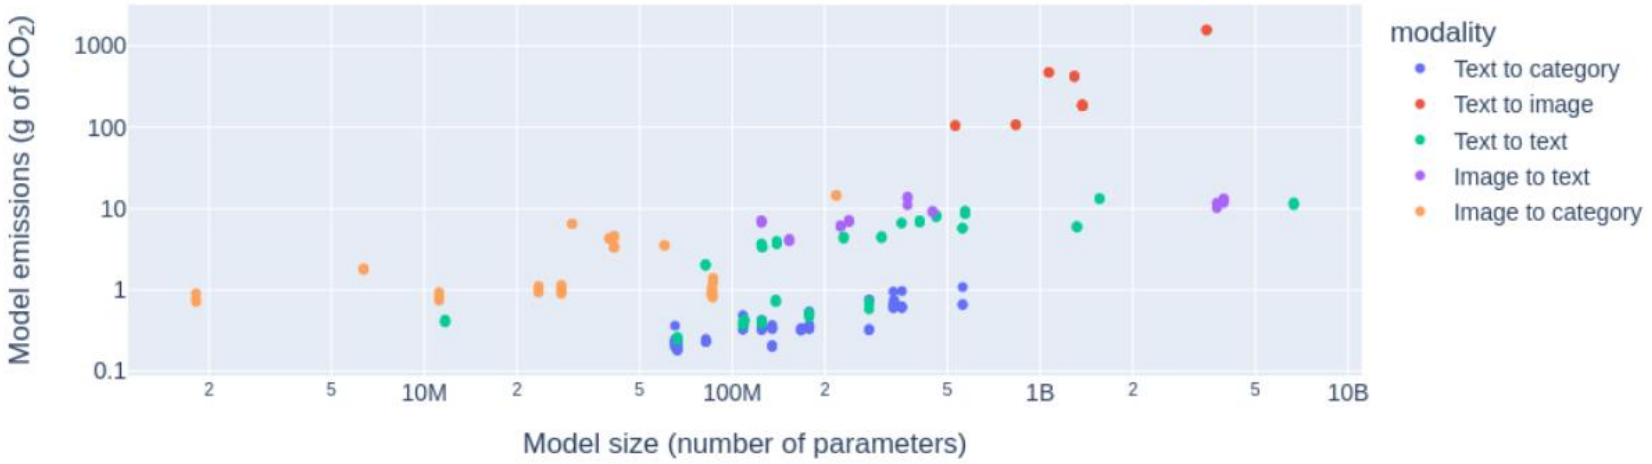


Figure 2: The 5 modalities examined in our study, with the number of parameters of each model on the x axis and the average amount of carbon emitted for 1000 inferences on the y axis. NB: Both axes are in logarithmic scale.

Luccioni S, Jernite Y, Strubell E. 2024. 高能耗处理：是什么在推高 AI 部署的能耗成本？. Proc. ACM conference on fairness, accountability, and transparency (pp. 85-99).

这一影响意味着什么？

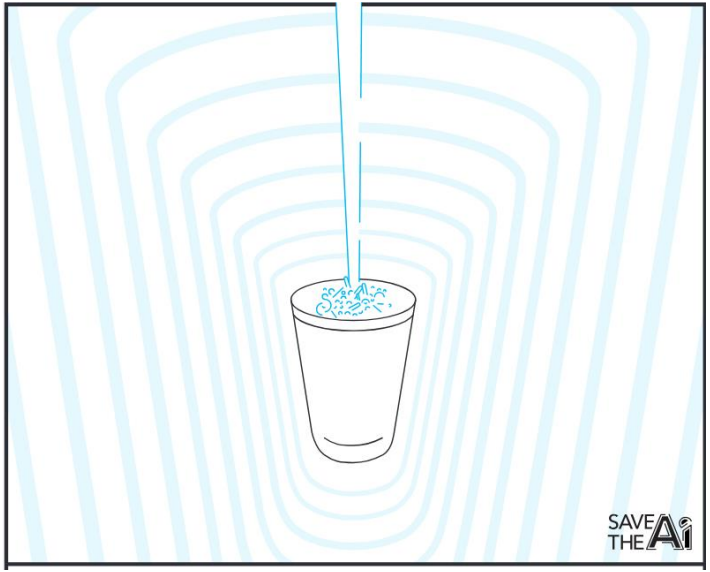
- 8 700 吨 CO_2 = 《巴黎协定》下 4 350 人的全年碳排放目标总量

据报道，OpenAI 使用了 30 000 块 A100 GPU 来维持其 AI 系统运行
（**Jean Zay 超算**拥有 1,456 块 H100 GPU 和 416 块 A100 GPU）

这一影响意味着什么？

水资源消耗持续攀升

使用 ChatGPT 撰写一封百词邮件或回答 10 个问题需消耗约 500 毫升水

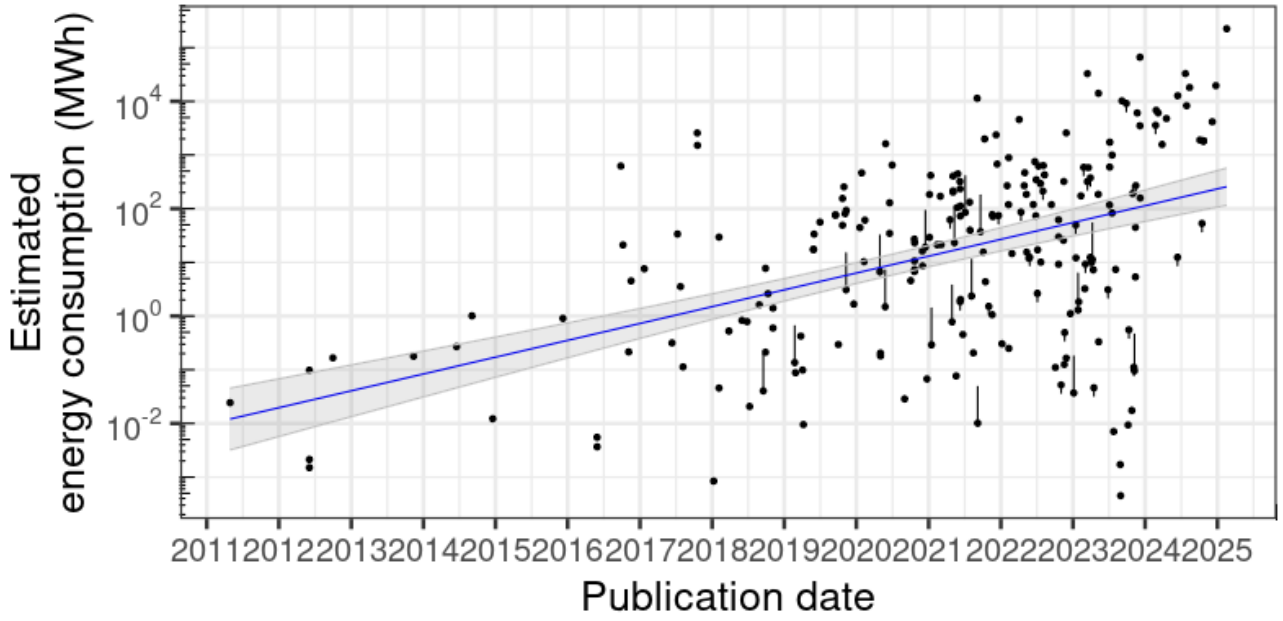


来源

Li P, Yang J, Islam MA, Ren S. (2023). 让 AI 不再“口渴”：揭示并解决 AI 模型隐秘的水足迹 *Communications of the ACM* 68(7), pp. 54-61.

这一影响意味着什么？

能源消耗持续攀升

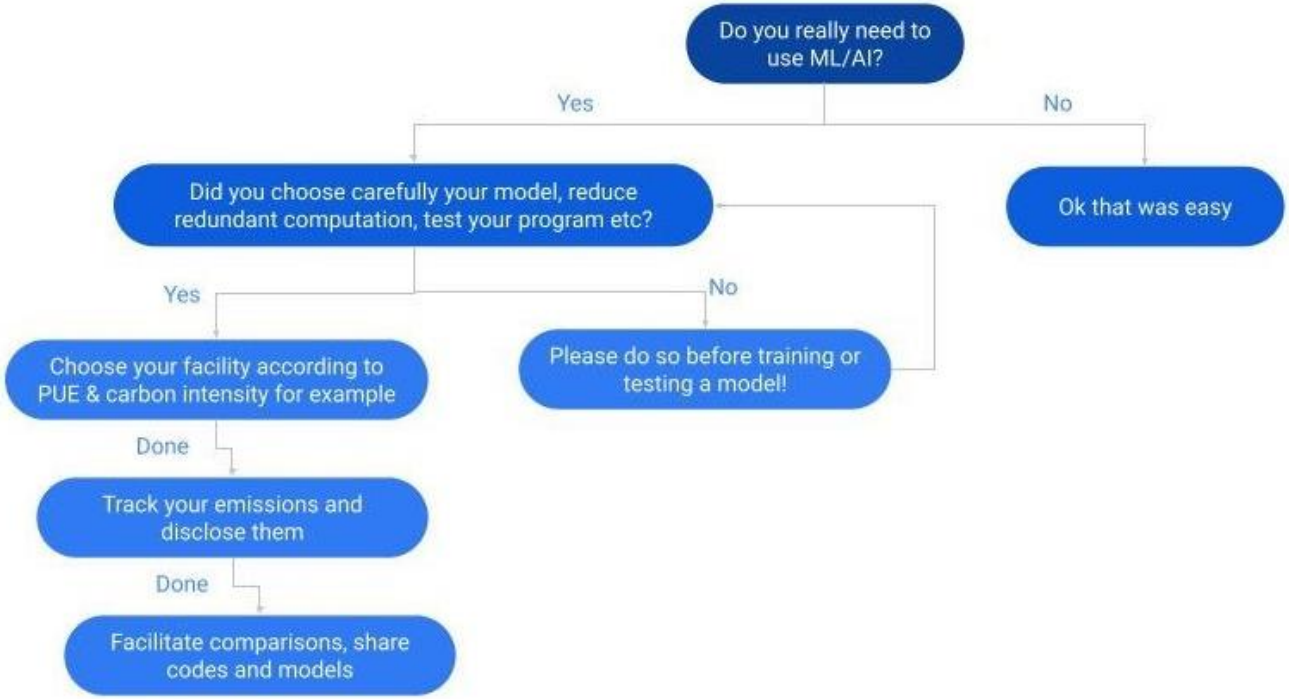


Morand C, Névéol A, Ligozat AL. AI 能有多绿色？机器学习环境影响趋势研究. arXiv:2412.17376

这些数据可靠吗？

- 计算过程需要依赖假设与近似估算
- **然而，从整体大局来看**：
  - **不同模型**间环境影响的相对差异依然成立
  - 总体环境影响依然巨大

我们能为此做些什么？



Ligozat AL. Luccioni S. 2021. 面向机器学习研究人员与从业者的碳排放量化实用指南

让计算更具环境可持续性的十条简单法则

- **法**则 1：**核算自身研究工作的碳足迹**
- **法**则 2：**将碳足迹**纳入成本效益分析
- **法**则 3：**妥善保留、**维修并重复利用设备，**以减少**电子废弃物
- **法**则 9：警**惕**软件效率提升引发的意外后果（**反**弹效应）

Lannelongue L, Grealey J, Bateman A, Inouye M (2021) 让计算更具环境可持续性的十条简单法则. PLoS Comput Biol 17(9): e1009324.

核心启示

评估应涵盖质量 + **影响**

⇒ 测量影响



议程

时间	活动	主讲人
9:00–9:10	介绍与开场	Min
9:10–9:40	伦理的哲学基础	Yajing, Esther, Yisong
9:40–10:05	环境与社会影响	Margot, Aurélie
10:05–10:30	小组讨论	*全体参与者*
10:30–11:00	☕ *茶歇* ☕	
11:00–11:40	小组展示	*全体参与者*
11:40–11:50	ACL 会议论文中的伦理考量章节	Yisong
11:50–12:20	语言表达与多语言偏见	Vamshi, Barid, Seunghun
12:20–12:30	总结与闭幕	

实践活动：
针对问题摘要的
小组讨论

全体参与者



茶歇



议程

时间	活动	主讲人
9:00–9:10	介绍与开场	Min
9:10–9:40	伦理的哲学基础	Yajing, Esther, Yisong
9:40–10:05	环境与社会影响	Margot, Aurélie
10:05–10:30	小组讨论	*全体参与者*
10:30–11:00	☕ *茶歇* ☕	
11:00–11:40	小组展示	*全体参与者*
11:40–11:50	ACL 会议论文中的伦理考量章节	Yisong
11:50–12:20	语言表达与多语言偏见	Vamshi, Barid, Seunghun
12:20–12:30	总结与闭幕	

https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

实践活动：
小组展示

全体参与者

议程

时间	活动	主讲人
9:00–9:10	介绍与开场	Min
9:10–9:40	伦理的哲学基础	Yajing, Esther, Yisong
9:40–10:05	环境与社会影响	Margot, Aurélie
10:05–10:30	小组讨论	*全体参与者*
10:30–11:00	 *茶歇* 	
11:00–11:40	小组展示	*全体参与者*
11:40–11:50	ACL 会议论文中的伦理考量章节	Yisong
11:50–12:20	语言表达与多语言偏见	Vamshi, Barid, Seunghun
12:20–12:30	总结与闭幕	

ACL 论文中的伦理考量章节

Yisong Miao
新加坡国立大学

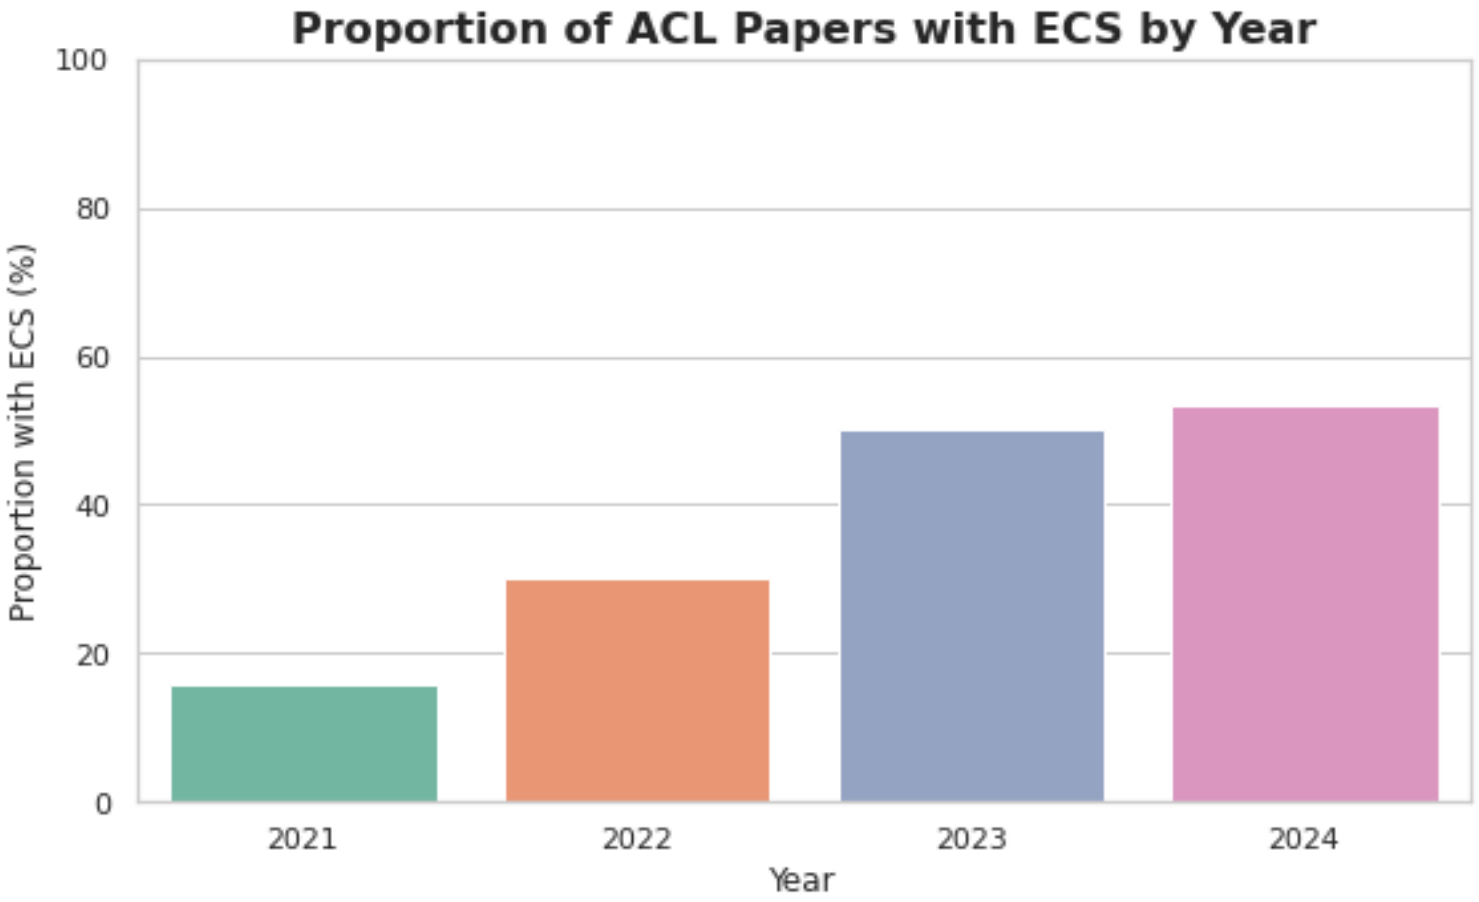
说明

本教程接下来这一部分的幻灯片改编自 Yulia Tsvetkov 的课程资料，已获授权使用。

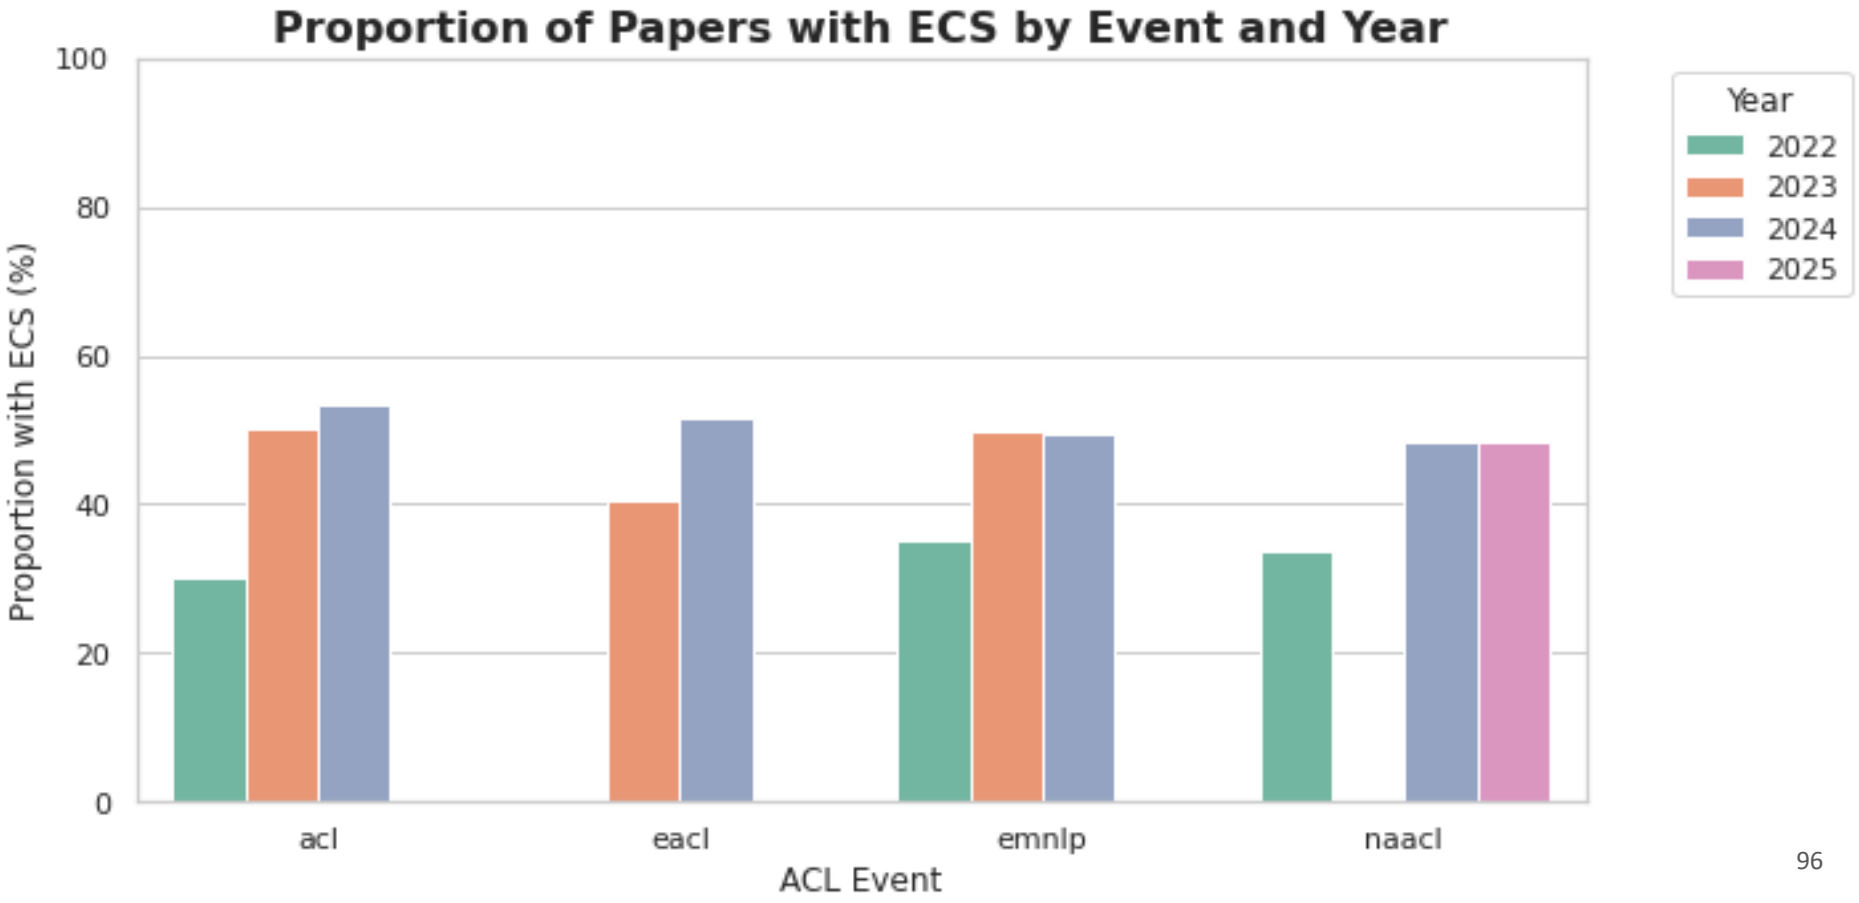
ACL 会议目前采取了哪些举措？

我们针对 ACL 2021-2025 论文中的伦理考量章节探讨以下三个问题：

1. **有多大比例的**论文包含伦理考量章节（ECS）？
2. ECS **是否回**应了建议探讨的伦理问题？比例如何？
3. **不同国家/地区在 ECS 方面是否存在差异？**



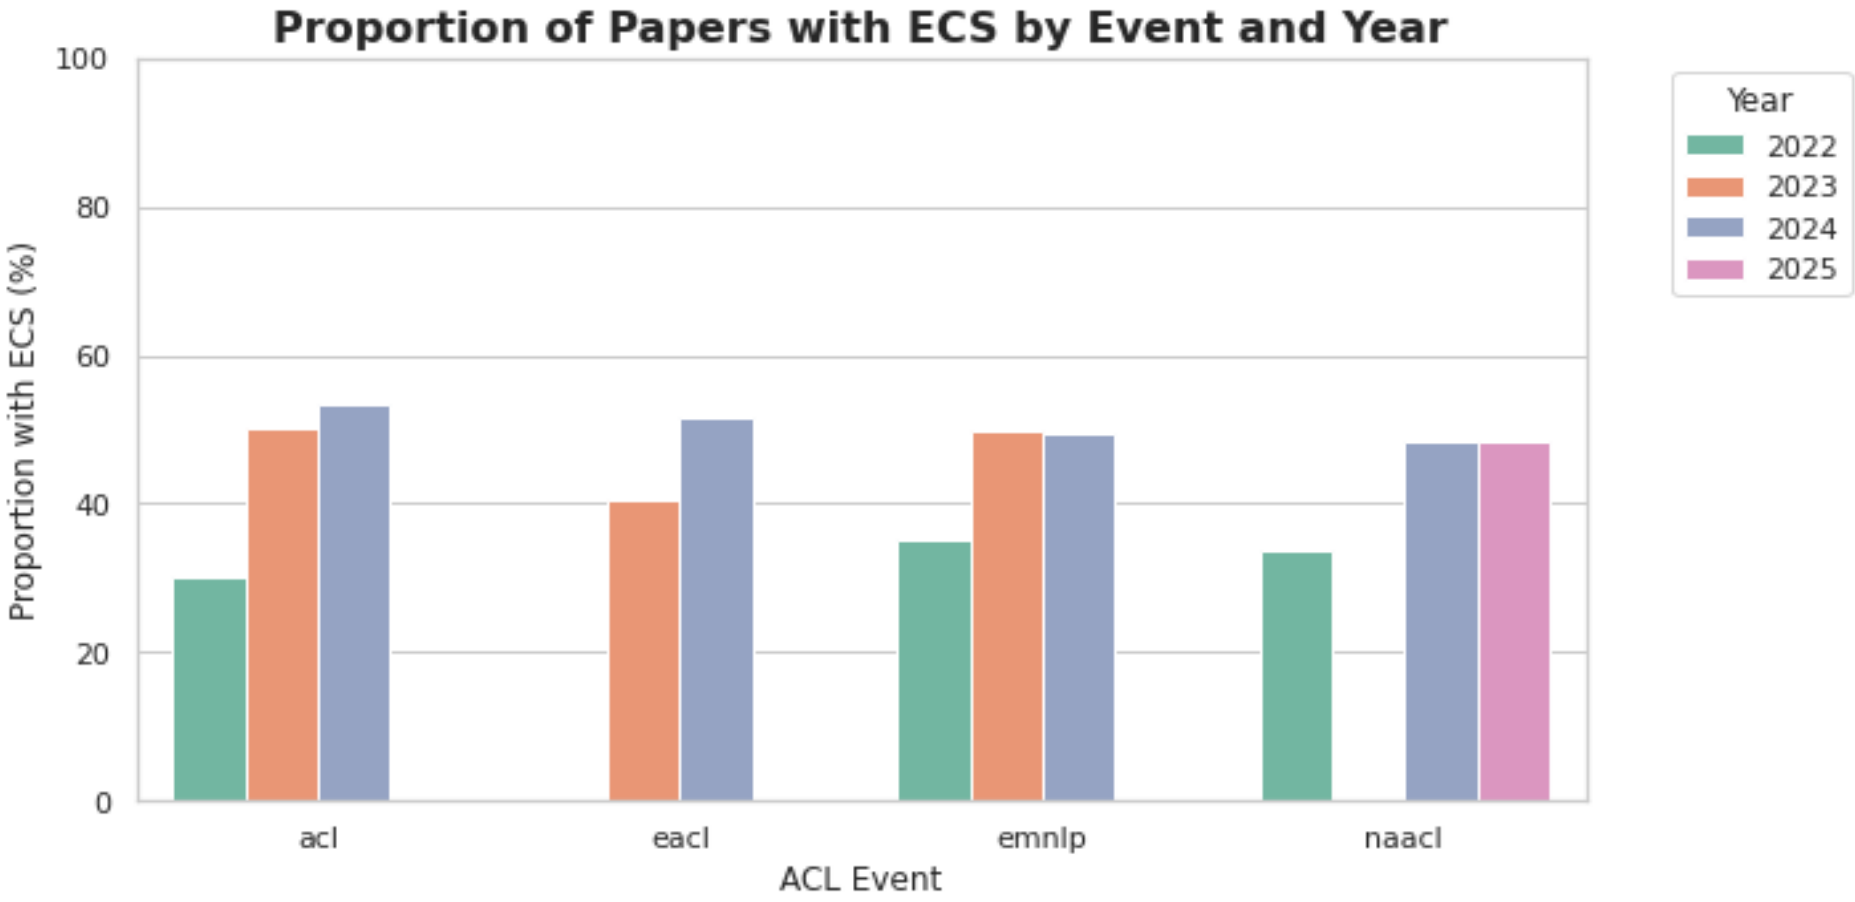
https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

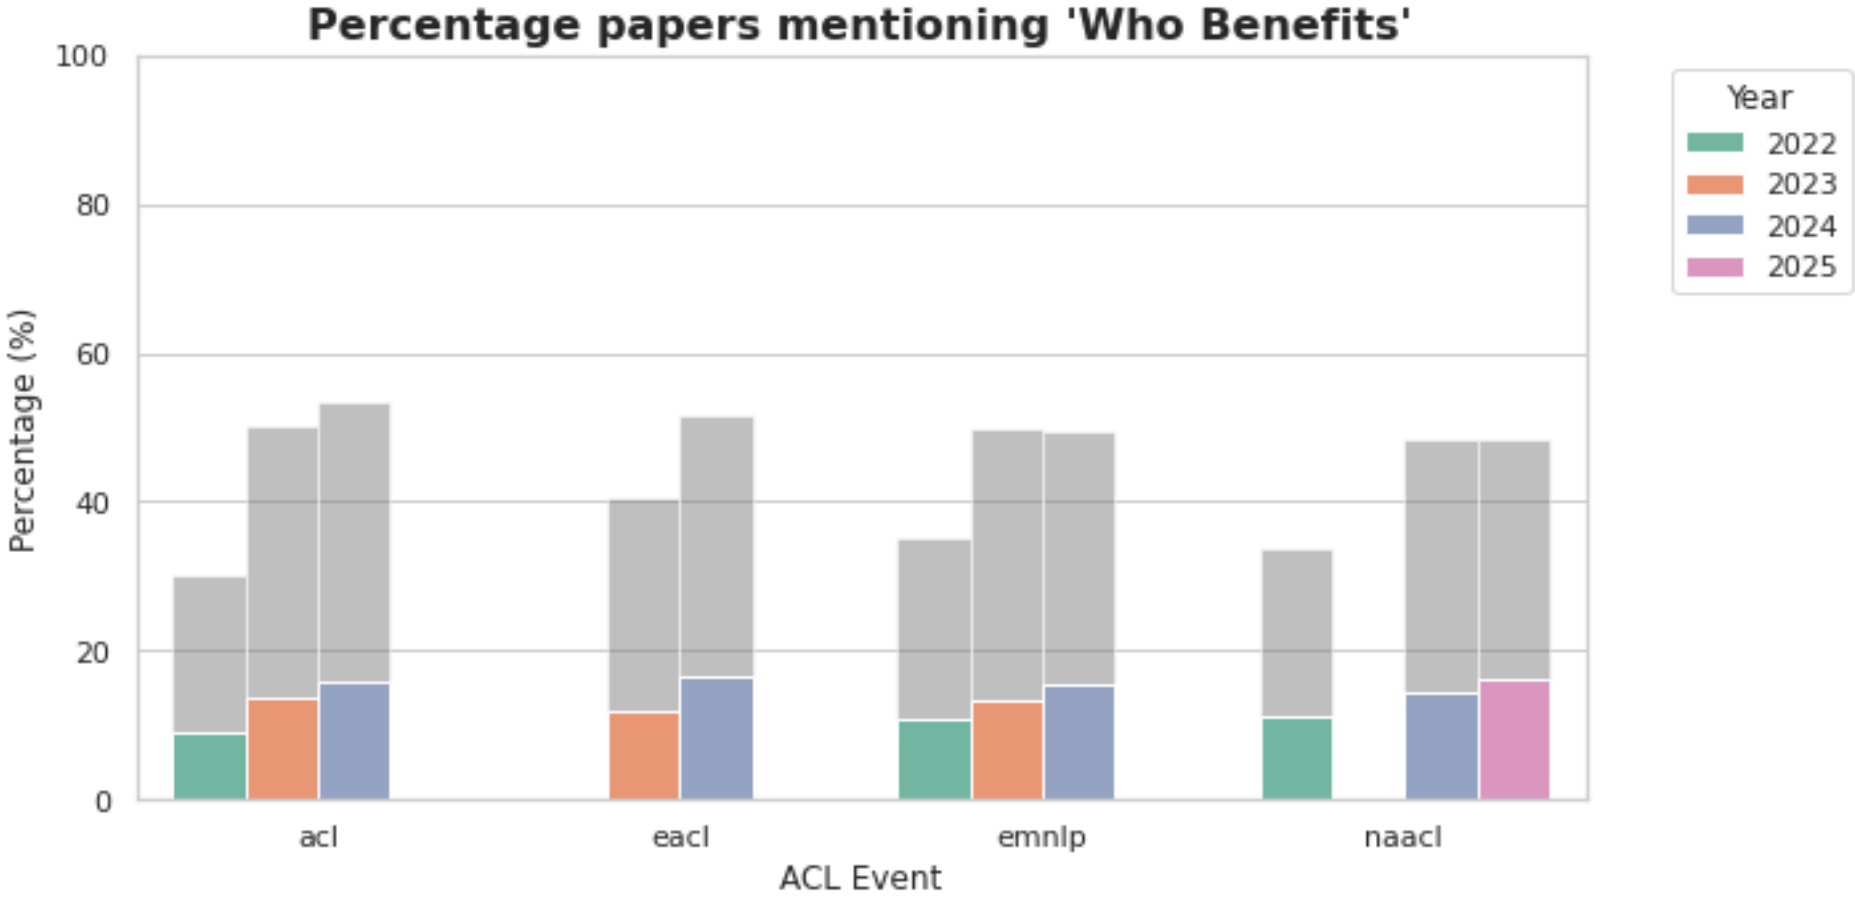


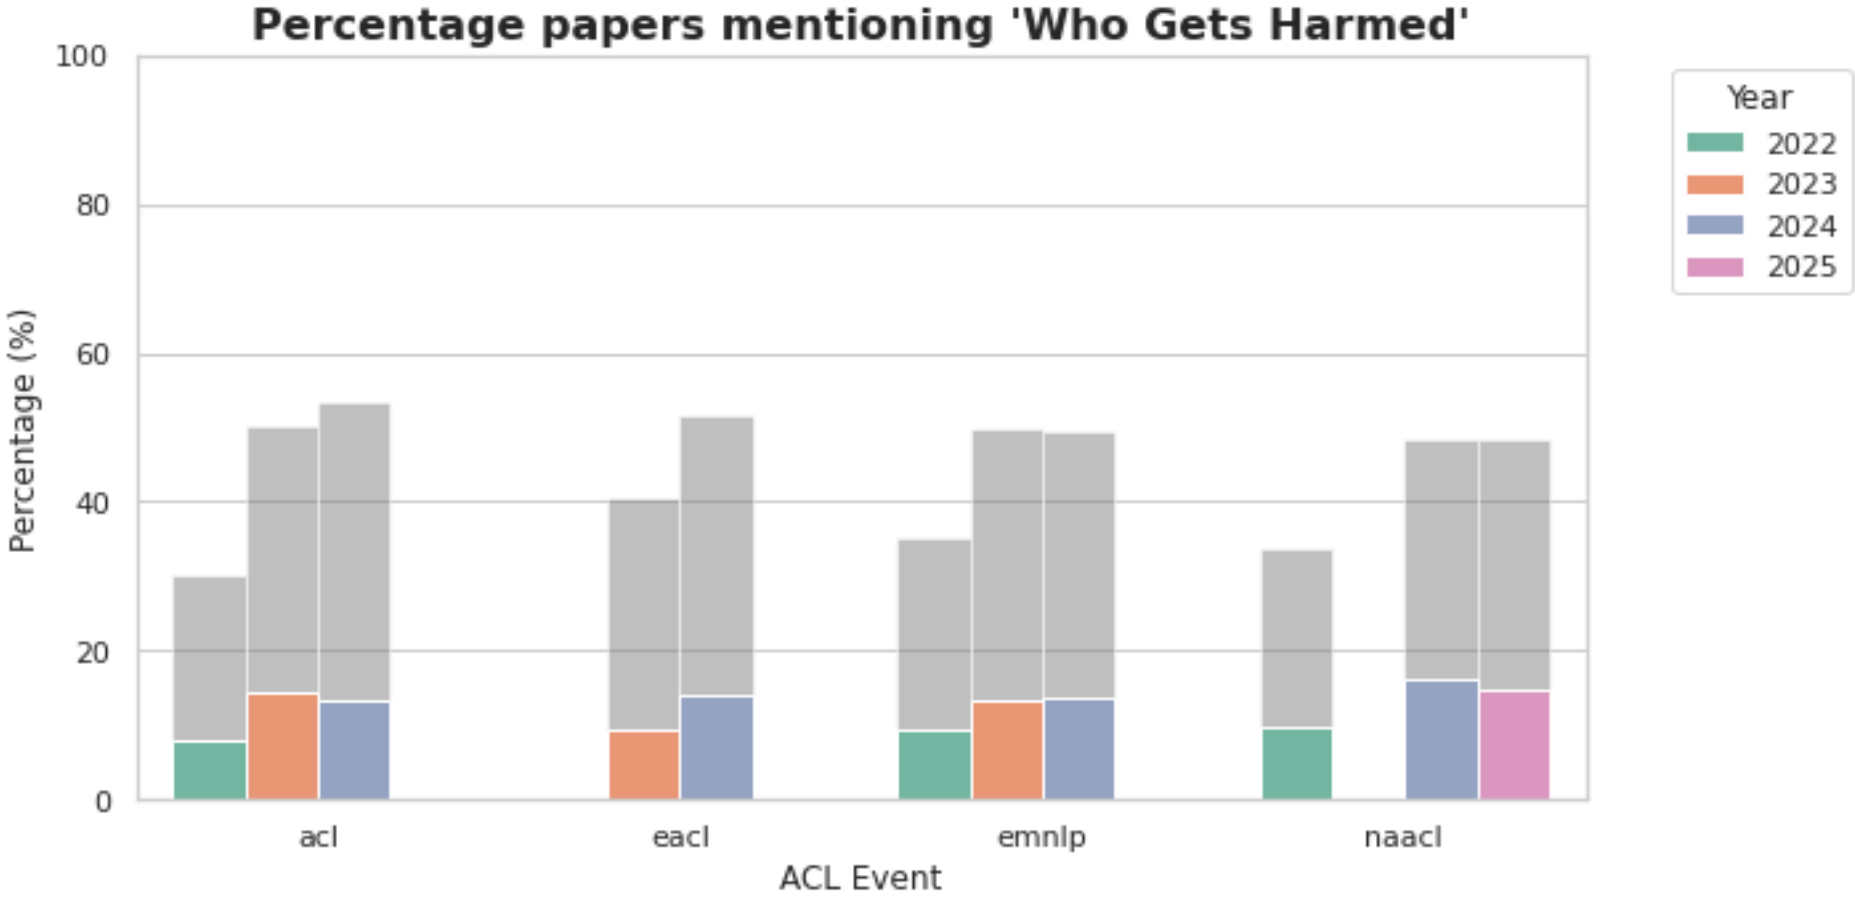
https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026

伦理考量章节的核心问题

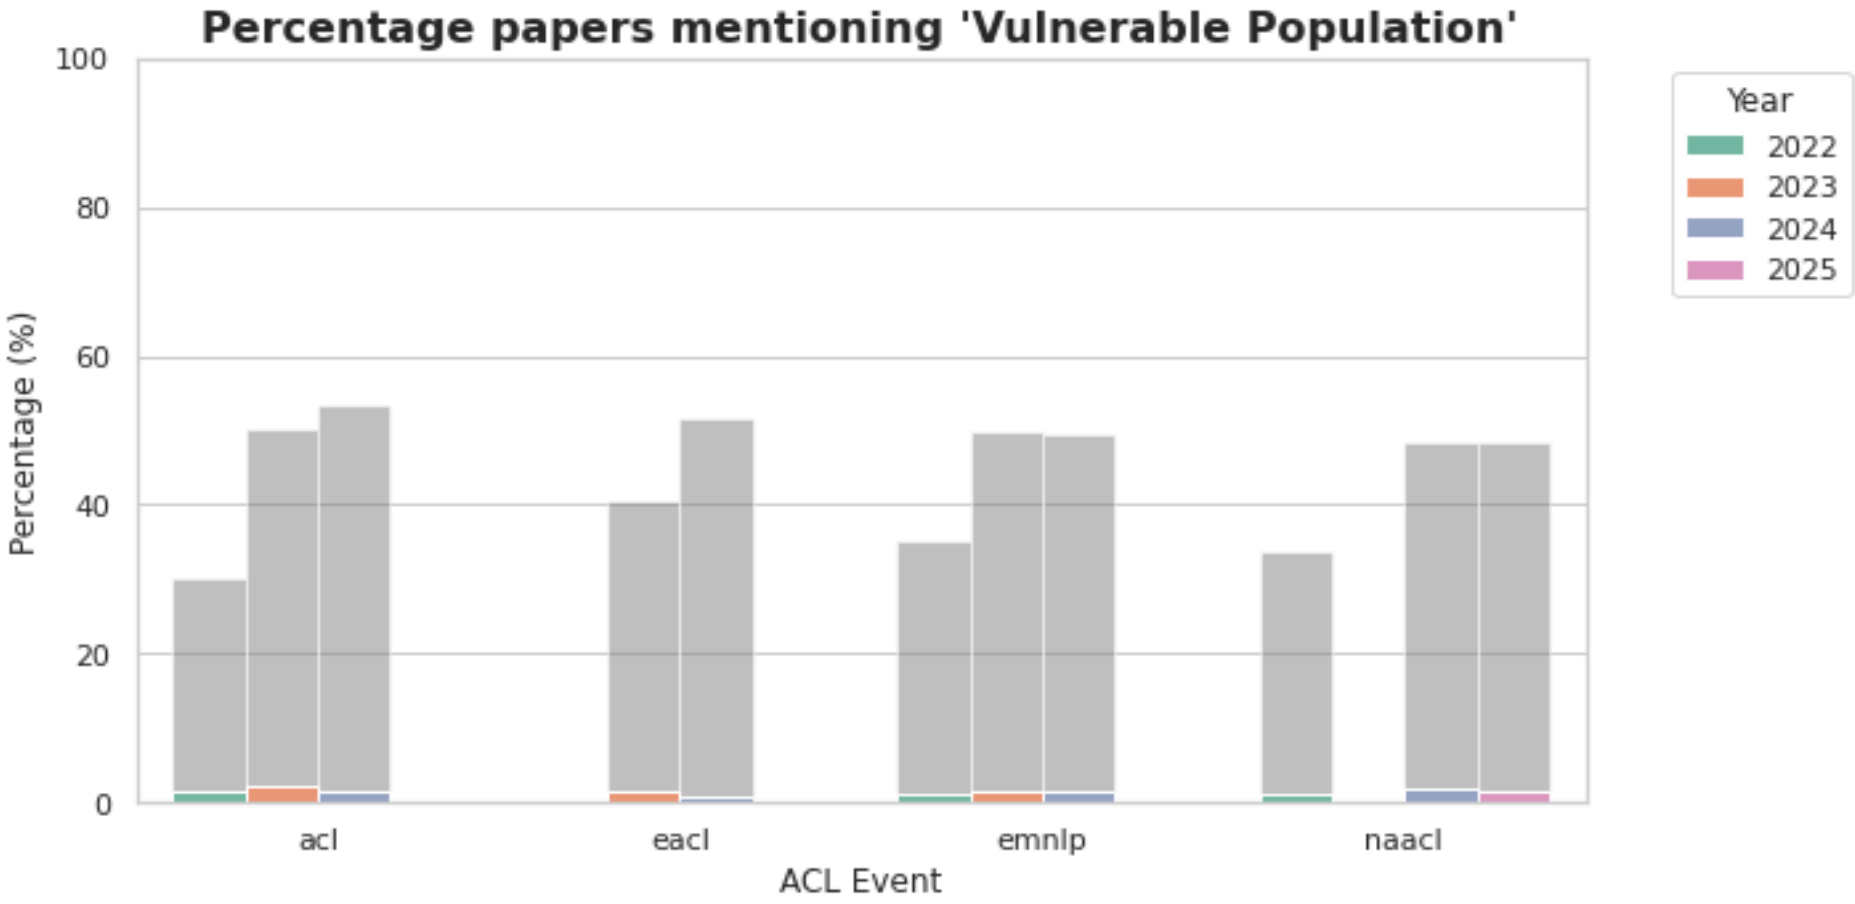
- **受益方（Benefits）：如果**该技术按预期运行，**谁会从中受益？**
- **危害（Harms）：如果**该技术按预期运行，**或者运行失败**，谁可能会受到何种伤害？**数据集和**训练模型中存在哪些偏见，**又会如何**导致这些**失效模式（例如：错误分析、错误分类）**？该技术存在哪些**潜在的滥用风险（例如：小范围滥用）**，**又可能随之**带来什么危害？
- **脆弱性（Vulnerabilities）：上述潜在危害是否可能会**对**本已处于边缘地位的弱势群体造成尤**为严重的冲击？**请全面考虑所有利益相关者**


Proportion of Papers with ECS by Event and Year
Proportion with ECS (%)
100
80
60
40
20
0
acl
eacl
emnlp
naacl
ACL Event
Year
2022
2023
2024
2025


Percentage papers mentioning 'Who Benefits'
100
80
60
40
20
0
Percentage (%)
acl
eacl
emnlp
naacl
ACL Event
Year
2022
2023
2024
2025



https://ethics.aclweb.org/tutorials/AACL_IJCNLP_2026


Percentage papers mentioning 'Vulnerable Population'
100
80
60
40
20
0
Percentage (%)
acl
eacl
emnlp
naacl
ACL Event
Year
2022
2023
2024
2025

结论

- 我们在伦理考量章节（ECS）中是否只讨论了表面问题？
- 仅靠伦理核查清单（checklists）就足够了吗？
- 我们难道不应该在 ECS 中直面根本性问题吗？
- 大语言模型正在改变格局：忽视谁会受到伤害将波及每一个人，而弱势群体首当其冲

议程

时间	活动	主讲人
9:00–9:10	介绍与开场	Min
9:10–9:40	伦理的哲学基础	Yajing, Esther, Yisong
9:40–10:05	环境与社会影响	Margot, Aurélie
10:05–10:30	小组讨论	*全体参与者*
10:30–11:00	 *茶歇* 	
11:00–11:40	小组展示	*全体参与者*
11:40–11:50	ACL 会议论文中的伦理考量章节	Yisong
11:50–12:20	语言表达与多语言偏见	Vamshi, Barid, Seunghun
12:20–12:30	总结与闭幕	

语言表达与多语言偏见

Vamshi Krishna Bonagiri
穆罕默德·本·扎耶德人工智能大学

Barid Xi Ai
新加坡国立大学

Seunghun J Lee
国际基督教大学

语言表达与偏见

语言表达涵盖两个层面：

1. **资源表达（Resource Representation）**：现有资源库、工具和应用中涵盖了哪些语言及语言变体。
2. **群体表达（Human Representation）**：**在用于构建**语料库和数据集的源文本中，语言**是如何呈**现与描述不同人群的。

实践活动

资源表达

模型了解你的文化吗？

模型误读你的文化的两种表现：

1. **文化抹除**（Erasure）：**模型退回到默**认的（通常是西方的）视角与框架。
2. **漫画化夸大**（Caricature）：**模型**矫枉过正，陷入刻板印象。

让我们来一探究竟：

1. **本活**动可以 2–3 **人一**组进行，也可以独立完成
2. 选择一种你们中至少有一人深入了解的文化（选择自己的文化会更容易）
3. **与任意大**语言模型开启一段临时/**无痕**对话（关闭记忆等功能）。我们建议使用任意**服**务商提供的免费版模型。

尝试用不同方式向你常用的模型输入以下提示词（Prompt）

我明天午餐应该做什么吃？（What should I make for lunch tomorrow?）

A. **使用英语**，不带文化提示词（cultural cue）
B. **英语 + 文化提示词：“我来自[某地]（I'm from [place]…）”**
C. （**可选**）使用你的母语，不带文化提示词

为我刚出生的女儿推荐几个名字（Suggest some names for my newborn daughter）

A. **使用英语**，不带文化提示词
B. **英语 + 文化提示词：“我来自[某地]（I'm from [place]…）”**
C. （**可选**）使用你的母语，不带文化提示词

注：对比 A **和** B **可以**观察到**“抹除”与“漫画化夸大”的差异**；对比 A **和** C **可以看出切**换语言是否会改变模型默认假定的文化背景。

请扫描使用 Qwen

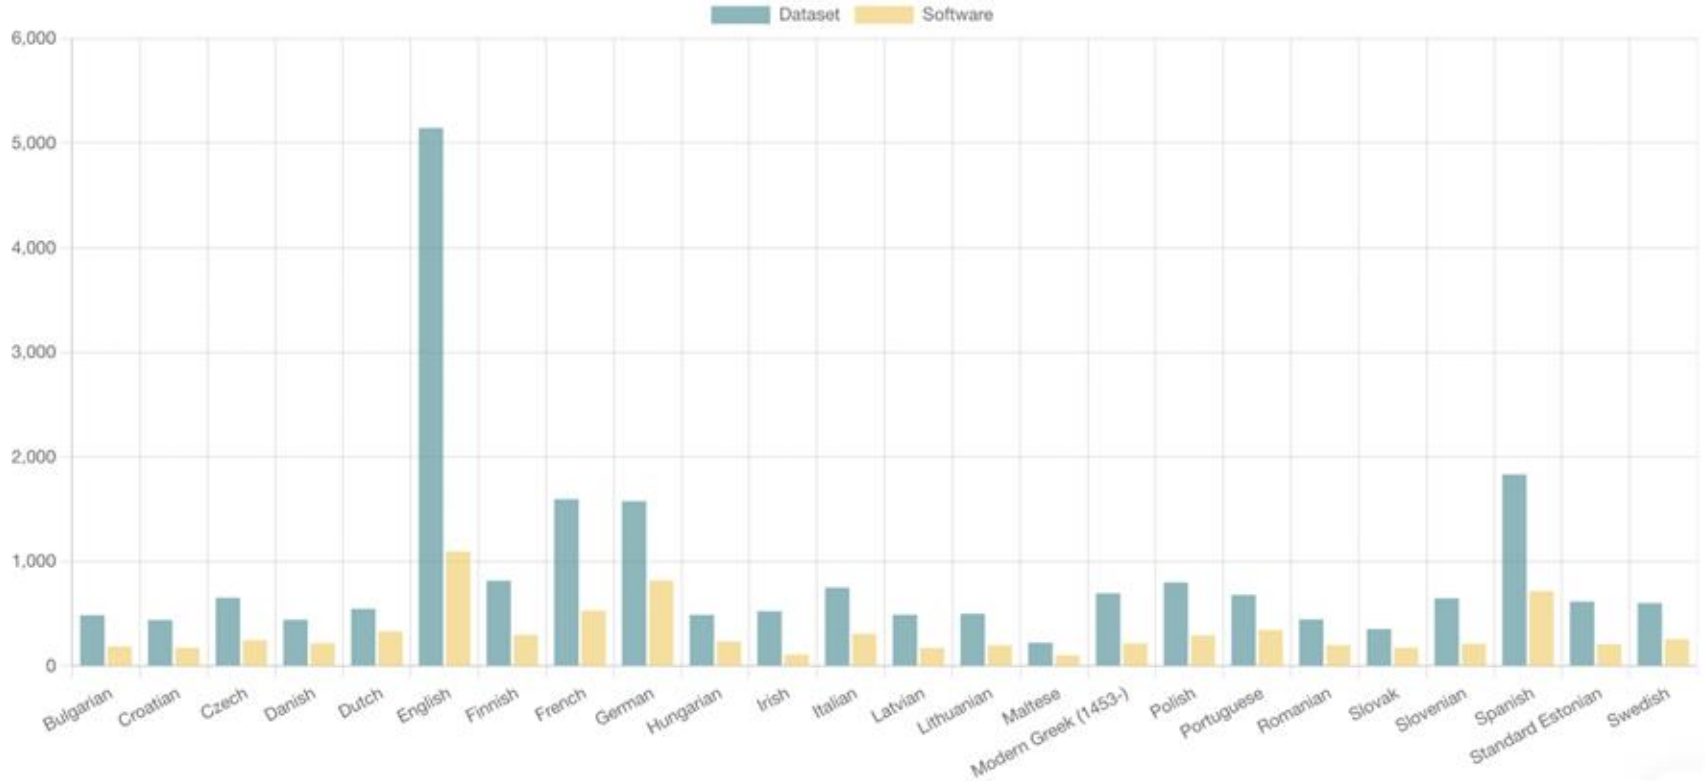
观察要点

- **默**认预设（Default）：**默**认假定西方或美国语境
- **漫画化夸大**（Caricature）：**流于刻板印象或**猎奇化（exoticizes）
- **事**实错误（Error）：**存在事**实性谬误
- 规范错位（Norm mismatch）：给出的建议在当地文化中并不合宜
- **跨**语言不一致（Inconsistent）：**切**换语言后回答发生实质性变化
- **合理**（OK）：**在**该文化内部人士看来自然妥当

记录你的测试结果并向小组汇报，你发现了什么？

你对模型的餐食建议满意吗？加入文化提示词（cultural cue）**有帮助**吗？切换语言**是否**带来了改变？

欧洲语言网格（European Language Grid）中的语言资源



Rehm, et al. (2024) 欧洲语言网格：一年之后（European Language Grid: One Year After） *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*.

通用依存关系（UD）资源库中各语言的可用树库数量

Abaza	1	Chukchi	1	Hittite	1	Maghrebi Arabic French	1	Pesh	1	Ukrainian	2
Abkhaz	1	Classical Armenian	1	Hungarian	1	Makurap	1	Phrygian	1	Umbrian	1
Afrikaans	1	Classical Chinese	2	Icelandic	4	Malayalam	1	Polish	3	Upper Sorbian	1
Akkadian	2	Coptic	2	Ika	1	Maltese	1	Pomak	1	Urdu	1
Akuntsu	1	Croatian	1	Indonesian	3	Manx	1	Portuguese	7	Uyghur	1
Albanian	2	Czech	6	Irish	3	Marathi	1	Romanian	5	Uzbek	2
Alemannic	1	Danish	1	Italian	10	Mbya Guarani	2	Russian	5	Veps	1
Amharic	1	Dutch	2	Japanese	6	Middle French	1	Sanskrit	2	Vietnamese	2
Ancient Greek	3	Egyptian	1	Javanese	1	Moksha	1	Scottish Gaelic	1	Warlpiri	1
Ancient Hebrew	1	English	12	Kaapor	1	Munduruku	1	Serbian	1	Welsh	1
Apurina	1	Erzya	1	Kangri	1	Naga	1	Sindhi	1	Western Armenian	1
Arabic	3	Esperanto	2	Karelian	1	Naija	1	Sinhala	1	Western S.P. Nahuatl	1
Armenian	2	Estonian	2	Karo	1	Nayini	1	Skolt Sami	1	Wolof	1
Assyrian	1	Faroese	2	Kazakh	1	Neapolitan	1	Slovak	1	Xavante	1
Azerbaijani	1	Finnish	4	Khoekhoe	1	Nenets	1	Slovenian	2	Xibe	1
Bambara	1	French	8	Khunsari	1	Nheengatu	1	Soi	1	Yakut	1
Basque	1	Frisian Dutch	1	Kiche	1	North Sami	1	South Levantine Arabic	1	Yoruba	1
Bavarian	1	Galician	3	Komi Permyak	1			Spanish	4	Yupik	1
Beja	1	Georgian	2	Komi Zyrian	2	Northwest Gbaya	1	Spanish Sign Language	1	Zaar	1
Belarusian	1	German	4	Korean	5	Norwegian	2	Swedish	3		
Bengali	1	Gheg	1	Kurmanji	1	Occitan	2	Swedish Sign Language	1		
Bhojpuri	1	Gothic	1	Kyrgyz	2	Odia	1	Tagalog	2		
Bokota	1	Greek	4	Latgalian	1	Old Church Slavonic	1	Tamil	2		
Bororo	1	Guajajara	1	Latin	6	Old East Slavic	4	Tatar	1		
Breton	1	Guarani	1	Latvian	2	Old English	1	Teko	1		
Bulgarian	1	Gujarati	1	Ligurian	1	Old French	1	Telugu	1		
Buryat	1	Gwichin	1	Lithuanian	2	Old Irish	2	Telugu English	1		
Cantonese	1	Haitian Creole	2	Livvi	1	Old Turkish	1	Thai	1		
Cappadocian	2	Hausa	2	Low Saxon	1	Ottoman Turkish	2	Tswana	1		
Catalan	1	Hebrew	3	Luxembourgish	1	Pashto	1	Tupinamba	1		
Cebuano	1	Highland P. Nahuatl	1	Macedonian	1	Paumari	1	Turkish	10		
Chinese	7	Hindi	2	Madi	1	Persian	2	Turkish English	1		

来源：https://universaldependencies.org/

“低资源（Low-resource）”在某种程度上是一种设计选择

NLP 领域常将模型性能不佳归因于某些语言的数据匮乏。但我们对海量数据的依赖，本身正是源于一系列设计选择：

- **高度数据**驱动的方法
- **追求峰**值准确率而非数据效率（data efficiency）
- 评测基准（benchmarks）倾向于奖励数据充裕场景下的性能表现

因此，性能上的不平等不应仅仅归咎于相关语言社区**“缺乏数据”**。

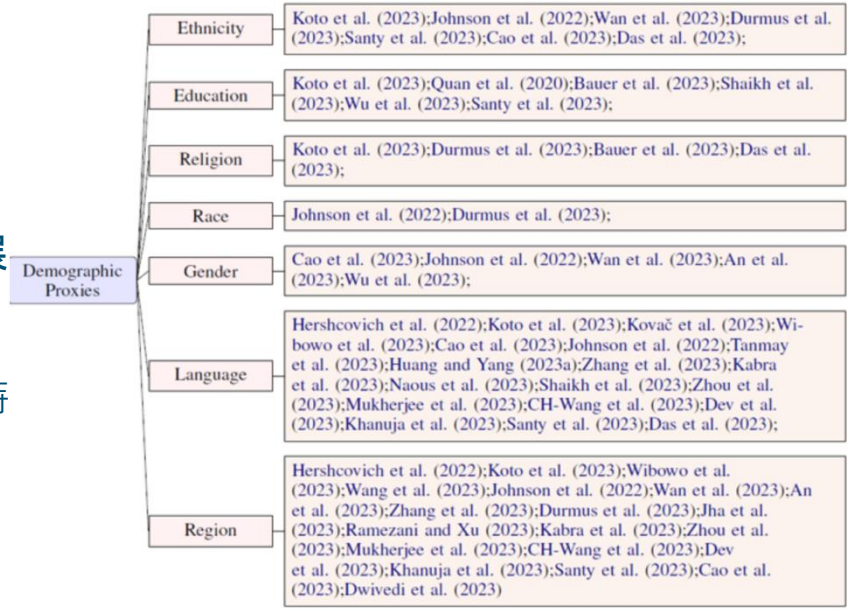
模型了解谁的文化？

当前的大语言模型往往对非西方文化呈现不足或存在误读。

关于文化的研究本身也存在不均衡现象：

- **只有部分群体受到研究关注**
- **只有部分文化特征得到量化**评估
- **在真**实情境化应用（situated applications）**中开展的**评估相对较少

因此，模型可能在通用评测基准上表现优异，却在特**定文化情境中**频频失效。



Adilazuarda et al. 大语言模型中“文化”的度量与建模综述（Towards measuring and modeling “culture” in LLMs: A survey）. Proceedings of the 2024 conference on empirical methods in natural language processing. 2024.

引导式讨论

群体表达

语言如何呈现与描述人群，以及为何这会传播偏见？

- 临床病历中存在污名化语言（stigmatizing language）；**用于指代患者的措辞会影响患者与医疗系统的互动方式。**
- **当**临床病历被用于构建 NLP **数据集和撰写**论文时，研究人员也会在无意间扩散带有污名化色彩**的**标签，从而加剧污名的传播。

污名化措辞（Stigmatizing wording）	**推荐用语（Recommended term）**
瘾君子、药物滥用者、酒鬼（addict, substance abuser, alcoholic）	**物**质使用障碍患者（person with a substance use disorder）
糖尿病人（标签化指代，diabetic）	**糖尿病患者**（person with diabetes）
精神分裂症者（标签化指代，schizophrenic）	**精神分裂症患者**（person with schizophrenia）
镰状细胞病患者（蔑称，sickler）	镰状细胞病患者（person with sickle cell disease

Healy, Richard and Kidia (2022). **如何减少**临床沟通中的污名与偏见：**叙述性**综述. *J Gen Intern Med.* 2022 Aug;37(10):2533-2540. doi:10.1007/s11606-022-07609-y. Epub. 2022 May 6. PMID: 35524034; PMCID: PMC9360372.

语言如何呈现与描述人群，以及为何这会传播偏见？

- 在心理语言学界，“母语者（native speaker）”等术语已受到质疑并被认为会伤害边缘化群体，因为这类概念强化了在语言使用、语言能力、语言习得及语言认同上的霸权观念。

  “当研究人员在工作中使用‘母语者（NATIVE SPEAKER）’这一概念，或因受试者不符合其对‘母语者’的预设而将其排除在研究之外时，实际上是在固化针对多语言现象及非主流语言习得模式的‘缺陷视角（deficit perspectives）’。”

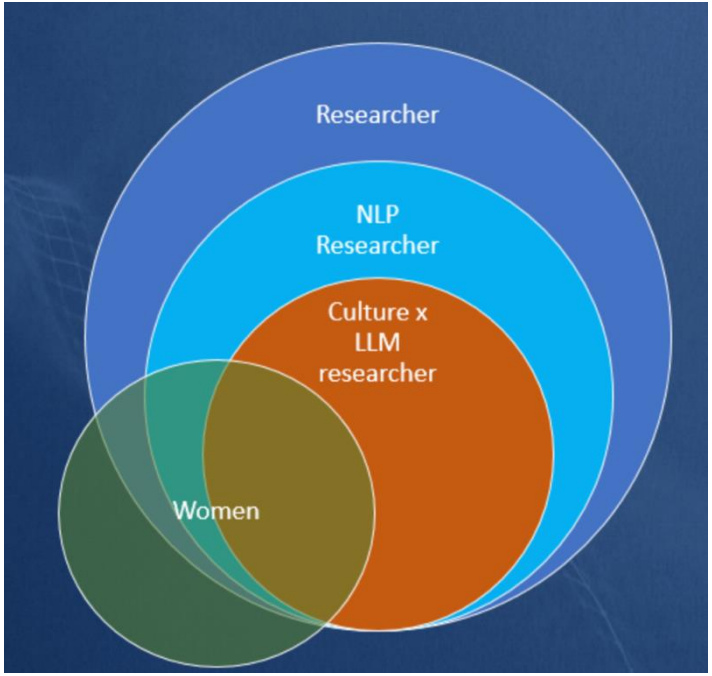
Cheng, et al. (2021) "心理语言学中存疑的“母语者”概念：用包容且准确的衡量标准替代模糊有害的术语." *Frontiers in Psychology* 12: 715843.

文化是良好的先验（prior），而非刻板标签

每个人都处于多重交叠文化的交汇点上。

来自同一国家、宗教、性别、代际或语言群体的人，其行为方式并非千篇一律。

文化信息有助于提供有价值的背景语境，但若将人口统计学类别视为决定性因素，同样会强化刻板印象。



Bender 法则及其拓展

Bender 法则（Bender Rule）：

1. **明确**说明研究所针对的具体语言。
2. **避免**隐含地将英语视为默认语言或通用语言。

将同样的原则拓展到语言之外。

1. **明确**说明：语言变体、地理与文化背景、目标受众群体
2. **明确**说明你的公平性定义：例如，若采用跨语言性能指标的平均值来确定最优**模型**，应说明这种做法所依据的公平性准则是什么。

议程

时间	活动	主讲人
9:00–9:10	介绍与开场	Min
9:10–9:40	伦理的哲学基础	Yajing, Esther, Yisong
9:40–10:05	环境与社会影响	Margot, Aurélie
10:05–10:30	小组讨论	*全体参与者*
10:30–11:00	 *茶歇* 	
11:00–11:40	小组展示	*全体参与者*
11:40–11:50	ACL 会议论文中的伦理考量章节	Yisong
11:50–12:20	语言表达与多语言偏见	Vamshi, Barid, Seunghun
12:20–12:30	总结与闭幕	

总结与闭幕

全体主讲人

行动倡议

伦理是一场必要的长期对话，需要我们每一个人的共同参与。

- **共同壮大学界的伦理审稿团队！**欢迎报名成为伦理审稿志愿者：请将您的**姓名登**记到共享文档中，助力我们扩充伦理审稿专家库。（***参与****伦理审稿还可相应抵扣您的常规论文审稿工作量！*）

- 欢迎将您知悉的相关文献补充到 ACL 伦理阅读清单（Ethics reading list）中！https://github.com/acl-org/ethics-reading-list

还有哪些值得补充的内容？

- Carolyn Rose 与 A. Seza Dugroz 开设的在线审稿课程：
  https://proton.oli.cmu.edu/sections/peer_review_course/enroll
  （如需了解更多信息，请发送邮件至：as.dogruoz@ugent.be）